Aprendizaje automático avanzado
Implementación de métodos de cálculo para representación de palabras

Juan Miguel Santos

Laboratorio de investigación y desarrollo experimental en computación (LIDEC)
Universidad Nacional de Hurlingham

(20 de agosto de 2026)

Implementación de métodos de cálculo

Introducción

- Para introducirnos en el método de cálculo consideraremos el caso donde una palabra debe ser predicha basada en la información de la palabra previa.
- Este tipo de modelo se denomina bigrama ya que se asume que el contexto está formado por una sola palabra (en este caso, a la izquierda de la palabra a predecir).

Implementación de métodos de cálculo

Introducción

- Para introducirnos en el método de cálculo consideraremos el caso donde una palabra debe ser predicha basada en la información de la palabra previa.
- Este tipo de modelo se denomina bigrama ya que se asume que el contexto está formado por una sola palabra (en este caso, a la izquierda de la palabra a predecir).

Implementación de métodos de cálculo

Introducción

- Consideraremos que las palabras en el corpus de documentos pertenecen a un diccionario V cuyo cardinal es $|V|$.
- El cálculo lo enmarcaremos en un perceptron multicapa en cuya entrada se presentará la palabra de contexto y en la salida la palabra a ser predicha.
- El perceptron multicapa tendrá una única capa oculta con N unidades, todas ellas con función de activación lineal $g(x) = x$.

Implementación de métodos de cálculo

Introducción

- Consideraremos que las palabras en el corpus de documentos pertenecen a un diccionario V cuyo cardinal es $|V|$.
- El cálculo lo enmarcaremos en un perceptron multicapa en cuya entrada se presentará la palabra de contexto y en la salida la palabra a ser predicha.
- El perceptron multicapa tendrá una única capa oculta con N unidades, todas ellas con función de activación lineal $g(x) = x$.

Implementación de métodos de cálculo

Introducción

- Consideraremos que las palabras en el corpus de documentos pertenecen a un diccionario V cuyo cardinal es $|V|$.
- El cálculo lo enmarcaremos en un perceptron multicapa en cuya entrada se presentará la palabra de contexto y en la salida la palabra a ser predicha.
- El perceptron multicapa tendrá una única capa oculta con N unidades, todas ellas con función de activación lineal $g(x) = x$.

Implementación de métodos de cálculo

Introducción

- La representación de las entradas será mediante la codificación *one-hot* al igual que la salida deseada.
- La función de activación de las unidades de salida será softmax.

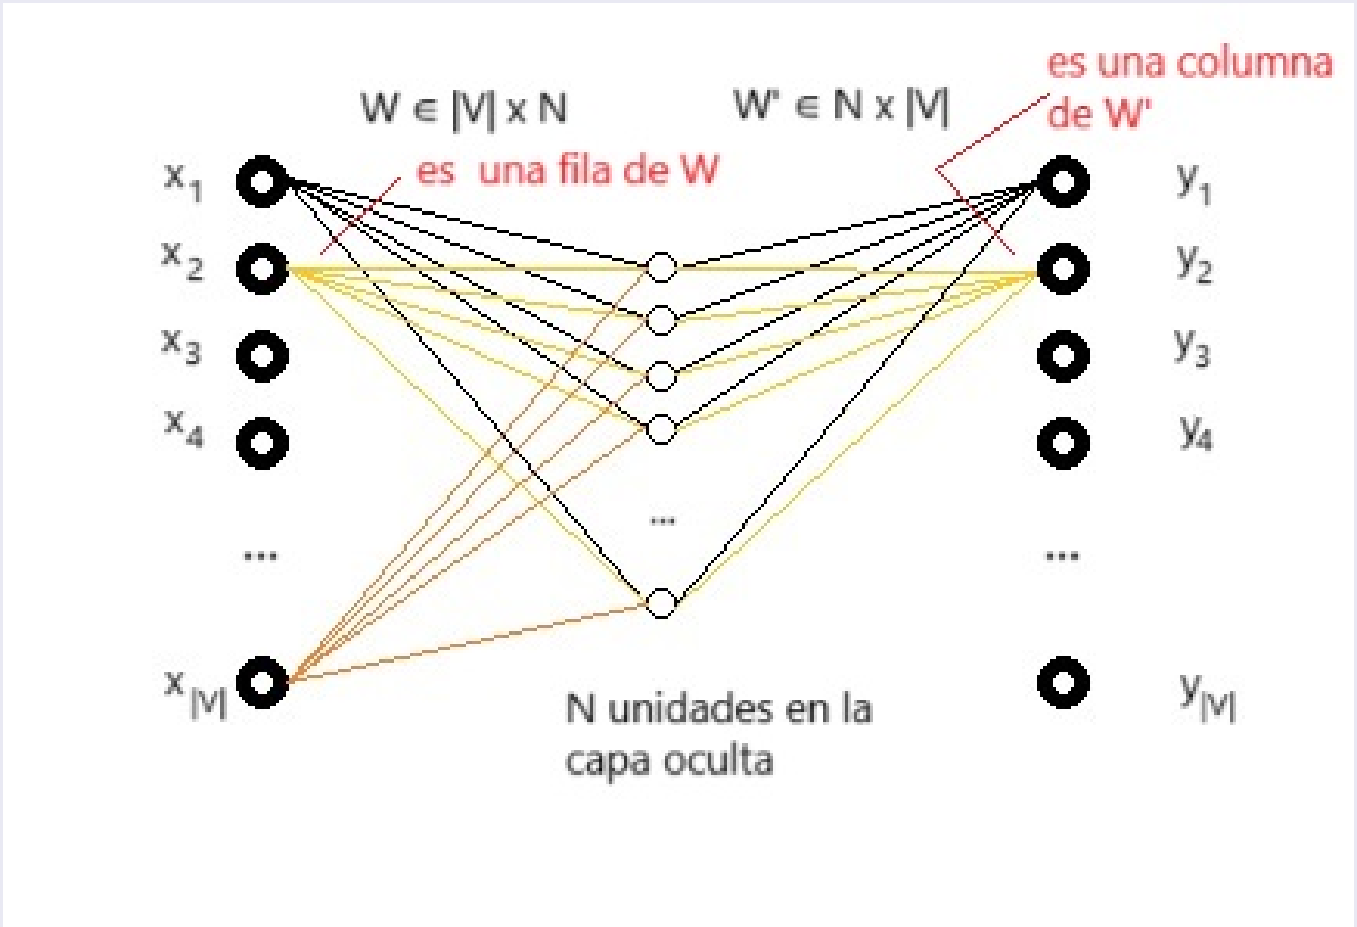
Implementación de métodos de cálculo

Introducción

- La representación de las entradas será mediante la codificación *one-hot* al igual que la salida deseada.
- La función de activación de las unidades de salida será softmax.

Implementación de métodos de cálculo

Arquitectura del perceptron multicapa utilizado



Implementación de métodos de cálculo

Introducción

- Cada palabra p_l se presentará en la entrada como un vector $x = (x_1, x_2, ..., x_{|V|})$ con sus elementos en cero excepto el elemento $i = l$ del vector que será 1:

$$(x_1 = 0, x_2 = 0, ..., x_i = 1, x_{i+1} = 0, .., x_{|V|} = 0).$$

- Los pesos de las conexiones entre la entrada y la capa oculta están representados por una matriz $W \in \mathbb{R}^{|V| \times N}$.
- Los pesos de las conexiones entre la capa oculta y la salida están representados por una matriz $W' \in \mathbb{R}^{N \times |V|}$.

Implementación de métodos de cálculo

Introducción

- Cada palabra p_l se presentará en la entrada como un vector $x = (x_1, x_2, ..., x_{|V|})$ con sus elementos en cero excepto el elemento $i = l$ del vector que será 1:

$$(x_1 = 0, x_2 = 0, ..., x_i = 1, x_{i+1} = 0, .., x_{|V|} = 0).$$

- Los pesos de las conexiones entre la entrada y la capa oculta están representados por una matriz $W \in \mathbb{R}^{|V| \times N}$.
- Los pesos de las conexiones entre la capa oculta y la salida están representados por una matriz $W' \in \mathbb{R}^{N \times |V|}$.

Implementación de métodos de cálculo

Introducción

- Cada palabra p_l se presentará en la entrada como un vector $x = (x_1, x_2, ..., x_{|V|})$ con sus elementos en cero excepto el elemento $i = l$ del vector que será 1:

$$(x_1 = 0, x_2 = 0, ..., x_i = 1, x_{i+1} = 0, .., x_{|V|} = 0).$$

- Los pesos de las conexiones entre la entrada y la capa oculta están representados por una matriz $W \in \mathbb{R}^{|V| \times N}$.
- Los pesos de las conexiones entre la capa oculta y la salida están representados por una matriz $W' \in \mathbb{R}^{N \times |V|}$.

Implementación de métodos de cálculo

Introducción

- La representación contextual de la palabra p_l la notaremos como v_{p_l}.
- El estado de activación de las unidades de la capa oculta lo notaremos con h y es calculado como:

$$h = W^t x = W^t_{(.,i)} = v^t_{p_l}$$

donde x es la representación *one-hot* de la palabra p_l.

Implementación de métodos de cálculo

Introducción

- La representación contextual de la palabra p_l la notaremos como v_{p_l}.
- El estado de activación de las unidades de la capa oculta lo notaremos con h y es calculado como:

$$h = W^t x = W^t_{(.,i)} = v^t_{p_l}$$

donde x es la representación *one-hot* de la palabra p_l.

Implementación de métodos de cálculo

Introducción

- Notar que, como x tiene una representación *one-hot*, el estado de activación h de la capa oculta será el vector columna $i = I$ de la matriz W^t o el vector fila $i = I$ de la matriz W.
- h no solo será el estado de activación de la capa oculta sino que también será la representación contextual v_{p_I} de la palabra p_I representada por x en codificación *one-hot*.

Implementación de métodos de cálculo

Introducción

- Notar que, como x tiene una representación *one-hot*, el estado de activación h de la capa oculta será el vector columna $i = I$ de la matriz W^t o el vector fila $i = I$ de la matriz W.
- h no solo será el estado de activación de la capa oculta sino que también será la representación contextual v_{p_I} de la palabra p_I representada por x en codificación *one-hot*.

Implementación de métodos de cálculo

Introducción

- El estado de excitación de cada unidad de salida lo notamos como u_j y es calculado como:

$$u_j = (v'_{p_j})^t h$$

donde v'_{p_j} es la columna j de la matriz W'.

- Luego, el estado de activación y_j de la unidad de salida j es calculado como:

$$y_j = \frac{\exp u_j}{\sum_{j'=1}^{|V|} \exp u_{j'}}.$$

Implementación de métodos de cálculo

Introducción

- El estado de excitación de cada unidad de salida lo notamos como u_j y es calculado como:

$$u_j = (v'_{p_j})^t h$$

donde v'_{p_j} es la columna j de la matriz W'.

- Luego, el estado de activación y_j de la unidad de salida j es calculado como:

$$y_j = \frac{\exp u_j}{\sum_{j'=1}^{|V|} \exp u_{j'}}.$$

Implementación de métodos de cálculo

Introducción

- Pero vimos más arriba que, $h = v_{p_l}^t$ y por lo tanto podemos reemplazar h en $u_j = (v'_{p_j})^t h$ y así obtenemos que:

$$u_j = (v'_{p_j})^t (v_{p_l})^t.$$

- Ahora que tenemos una nueva expresión de u_j podemos reemplazar u_j en $y_j = \frac{\exp u_j}{\sum_{j'=1}^{|V|} \exp u_{j'}}$ y así nos queda que

$$y_j = \frac{\exp\left((v'_{p_j})^t (v_{p_l})^t\right)}{\sum_{j'=1}^{|V|} \exp\left((v'_{p_{j'}})^t (v_{p_l})^t\right)}.$$

Implementación de métodos de cálculo

Introducción

- Pero vimos más arriba que, $h = v_{p_l}^t$ y por lo tanto podemos reemplazar h en $u_j = (v'_{p_j})^t h$ y así obtenemos que:

$$u_j = (v'_{p_j})^t (v_{p_l})^t.$$

- Ahora que tenemos una nueva expresión de u_j podemos reemplazar u_j en $y_j = \frac{\exp u_j}{\sum_{j'=1}^{|V|} \exp u_{j'}}$ y así nos queda que

$$y_j = \frac{\exp\left((v'_{p_j})^t (v_{p_l})^t\right)}{\sum_{j'=1}^{|V|} \exp\left((v'_{p_{j'}})^t (v_{p_l})^t\right)}.$$

Implementación de métodos de cálculo

Introducción

- En la expresión recién obtenida el producto entre vectores está representado como producto entre matrices (de ahí la necesidad de transponer)

$$y_j = \frac{\exp\left((v'_{p_j})^t (v_{p_l})^t\right)}{\sum_{j'=1}^{|V|} \exp\left((v'_{p_{j'}})^t (v_{p_l})^t\right)}.$$

Implementación de métodos de cálculo

Introducción

- Sin embargo, podemos expresar dichos productos directamente como productos internos simplificando la notación:

$$y_j = \frac{\exp\left(v'_{p_j} v_{p_l}\right)}{\sum_{j'=1}^{|V|} \exp\left(v'_{p_{j'}} v_{p_l}\right)}.$$

Implementación de métodos de cálculo

Introducción

- Prestemos atención al numerador y denominador de la expresión de y_j.
- El numerador es la exponencial del producto interno entre v'_{p_j} y v_{p_l} que son las representaciones de p_j y p_l.
- El denominador es la suma de todas las exponenciales de los productos internos entre todas las representaciones de las palabras $p_{j'}$ y p_l, $1 \leq j' \leq |V|$.
- Pero esto es lo que definimos en la clase pasada como

$$P(p_j \mid p_l).$$

Implementación de métodos de cálculo

Introducción

- Prestemos atención al numerador y denominador de la expresión de y_j.
- El numerador es la exponencial del producto interno entre v'_{p_j} y v_{p_I} que son las representaciones de p_j y p_I.
- El denominador es la suma de todas las exponenciales de los productos internos entre todas las representaciones de las palabras $p_{j'}$ y p_I, $1 \leq j' \leq |V|$.
- Pero esto es lo que definimos en la clase pasada como

$$P(p_j \mid p_I).$$

Implementación de métodos de cálculo

Introducción

- Prestemos atención al numerador y denominador de la expresión de y_j.
- El numerador es la exponencial del producto interno entre v'_{p_j} y v_{p_I} que son las representaciones de p_j y p_I.
- El denominador es la suma de todas las exponenciales de los productos internos entre todas las representaciones de las palabras $p_{j'}$ y p_I, $1 \leq j' \leq |V|$.
- Pero esto es lo que definimos en la clase pasada como

$$P(p_j \mid p_I).$$

Implementación de métodos de cálculo

Introducción

- Prestemos atención al numerador y denominador de la expresión de y_j.
- El numerador es la exponencial del producto interno entre v'_{p_j} y v_{p_I} que son las representaciones de p_j y p_I.
- El denominador es la suma de todas las exponenciales de los productos internos entre todas las representaciones de las palabras $p_{j'}$ y p_I, $1 \leq j' \leq |V|$.
- Pero esto es lo que definimos en la clase pasada como

$$P(p_j \mid p_I).$$

Implementación de métodos de cálculo

Introducción

- Por lo tanto, vamos a interpretar a y_j como $P(p_j \mid p_l)$, esto es:

$$p(p_j \mid p_l) = y_j = \frac{\exp u_j}{\sum_{j'=1}^{|V|} \exp u_{j'}}.$$

Implementación de métodos de cálculo

Introducción

- Analicemos esto mismo desde otro punto de vista.
- Fijarse que y_j es el estado de activación de la unidad j cuando en la entrada se ha presentado la representación *one-hot* de la palabra p_l.
- Si la red predijera correctamente y la palabra deseada tuviera una representación de 0s excepto para el elemento j, y_j debiera ser 1.

Implementación de métodos de cálculo

Introducción

- Analicemos esto mismo desde otro punto de vista.
- Fijarse que y_j es el estado de activación de la unidad j cuando en la entrada se ha presentado la representación *one-hot* de la palabra p_l.
- Si la red predijera correctamente y la palabra deseada tuviera una representación de 0s excepto para el elemento j, y_j debiera ser 1.

Implementación de métodos de cálculo

Introducción

- Analicemos esto mismo desde otro punto de vista.
- Fijarse que y_j es el estado de activación de la unidad j cuando en la entrada se ha presentado la representación *one-hot* de la palabra p_l.
- Si la red predijera correctamente y la palabra deseada tuviera una representación de 0s excepto para el elemento j, y_j debiera ser 1.

Implementación de métodos de cálculo

Introducción

- Sin embargo, como la palabra deseada es la que le sigue a p_l en el texto, podría ocurrir que hubiera más de una palabra deseada posible:

  'El **perro** furioso corrió hacia la esquina.'.

  y

  'El **perro** ladraba intensamente.'.

- En este caso, la palabra sucesora de 'perro' no solo es 'furioso' sino que también 'ladraba', de modo que, ahora y_k debe ser 1, donde la representación *one-hot* de la palabra 'ladraba' tiene un 1 en el elemento k y el resto en 0.

Implementación de métodos de cálculo

Introducción

- Sin embargo, como la palabra deseada es la que le sigue a p_l en el texto, podría ocurrir que hubiera más de una palabra deseada posible:

  'El **perro** furioso corrió hacia la esquina.'.

  y

  'El **perro** ladraba intensamente.'.

- En este caso, la palabra sucesora de 'perro' no solo es 'furioso' sino que también 'ladraba', de modo que, ahora y_k debe ser 1, donde la representación *one-hot* de la palabra 'ladraba' tiene un 1 en el elemento k y el resto en 0.

Implementación de métodos de cálculo

Introducción

- Dado que $y_j = P(p_j \mid p_l)$ esto es lo que vamos a maximizar. Es decir, queremos que cuando en un texto aparece la palabra p_l su sucesora sea p_j y por lo tanto necesitaremos que y_j sea máxima.
- Caso contrario, queremos que $y_{j'}$ sea menor a y_j, $\forall j' \neq j$.
- Nota: si se desea que y_j sea máxima (es decir, valga 1), al ser la función de activación en la salida una soft-max, necesariamente se minimizarán los $y_{j'}$ para $j' \neq j$.

Implementación de métodos de cálculo

Introducción

- Dado que $y_j = P(p_j \mid p_l)$ esto es lo que vamos a maximizar. Es decir, queremos que cuando en un texto aparece la palabra p_l su sucesora sea p_j y por lo tanto necesitaremos que y_j sea máxima.
- Caso contrario, queremos que $y_{j'}$ sea menor a y_j, $\forall j' \neq j$.
- Nota: si se desea que y_j sea máxima (es decir, valga 1), al ser la función de activación en la salida una soft-max, necesariamente se minimizarán los $y_{j'}$ para $j' \neq j$.

Implementación de métodos de cálculo

Introducción

- Dado que $y_j = P(p_j \mid p_l)$ esto es lo que vamos a maximizar. Es decir, queremos que cuando en un texto aparece la palabra p_l su sucesora sea p_j y por lo tanto necesitaremos que y_j sea máxima.
- Caso contrario, queremos que $y_{j'}$ sea menor a y_j, $\forall j' \neq j$.
- Nota: si se desea que y_j sea máxima (es decir, valga 1), al ser la función de activación en la salida una soft-max, necesariamente se minimizarán los $y_{j'}$ para $j' \neq j$.

Implementación de métodos de cálculo

Introducción

- Sea j^* el índice de la palabra sucesora (u objetivo o deseada) queremos obtener el máximo de $P(p_{j^*} \mid p_l)$, esto es

$$\text{máx}\, y_{j^*}$$

$$\text{máx} \log y_{j^*}$$

$$\text{máx}(u_{j^*} - \log \sum_{j'=1}^{|V|} \exp u_{j'}).$$

Implementación de métodos de cálculo

Introducción

- Si notamos $-E = u_{j^*} - \log \sum_{j'=1}^{|V|} \exp u_{j'}$ lo que querremos es minimizar E dado por

$$E = \log \sum_{j'=1}^{|V|} \exp(u_{j'}) - u_{j^*}$$

Implementación de métodos de cálculo

Introducción

- Para calcular la actualización de los pesos de W' vamos primero a derivar E respecto de u_j

$$\frac{\partial E}{\partial u_j} = \frac{1}{\sum_{j'=1}^{|V|} \exp u_{j'}} \exp u_j - t_j = y_j - t_j = e_j$$

donde

$$t_j = \begin{cases} 1 & \text{si } j = j^*, \\ 0 & \text{en otro caso.} \end{cases}$$

Implementación de métodos de cálculo

Introducción

- Ahora derivamos respecto a w'_{ij}

$$\frac{\partial E}{\partial w'_{ij}} = \frac{\partial E}{\partial u_j}\frac{\partial u_j}{\partial w'_{ij}} = e_j h_i$$

donde,

$$\frac{\partial E}{\partial w'_{ij}} = \begin{cases} (y_j - 1)h_i & \text{si } j = j^*, \\ y_j h_i & \text{en otro caso.} \end{cases}$$

Implementación de métodos de cálculo

Introducción. Nota.

- Recordar que u_j lo habíamos definido como $u_j = (v'_j)^t h$, y v'_j es como llamamos a los vectores columnas de W'.
- $W' \in \mathbb{R}^{N \times |V|}$ y por lo tanto $v'_j \in \mathbb{R}^{N \times 1}$.
- Así, $u_j = (v'_j)^t h$ la podemos escribir como $u_j = v'_j h$, o sea:

$$u_j = \sum_{k=1}^{N} (v'_{kj}) h_k = \sum_{k=1}^{N} (w'_{kj}) h_k.$$

Implementación de métodos de cálculo

Introducción. Nota.

- Recordar que u_j lo habíamos definido como $u_j = (v'_j)^t h$, y v'_j es como llamamos a los vectores columnas de W'.
- $W' \in \mathbb{R}^{N \times |V|}$ y por lo tanto $v'_j \in \mathbb{R}^{N \times 1}$.
- Así, $u_j = (v'_j)^t h$ la podemos escribir como $u_j = v'_j h$, o sea:

$$u_j = \sum_{k=1}^{N} (v'_{kj}) h_k = \sum_{k=1}^{N} (w'_{kj}) h_k.$$

Implementación de métodos de cálculo

Introducción. Nota.

- Recordar que u_j lo habíamos definido como $u_j = (v'_j)^t h$, y v'_j es como llamamos a los vectores columnas de W'.
- $W' \in \mathbb{R}^{N \times |V|}$ y por lo tanto $v'_j \in \mathbb{R}^{N \times 1}$.
- Así, $u_j = (v'_j)^t h$ la podemos escribir como $u_j = v'_j h$, o sea:

$$u_j = \sum_{k=1}^{N} (v'_{kj}) h_k = \sum_{k=1}^{N} (w'_{kj}) h_k.$$

Implementación de métodos de cálculo

Introducción. Nota.

- Si derivamos u_j respecto a w'_{ij} tenemos que

$$\frac{\partial u_j}{\partial w'_{ij}} = \frac{\partial \sum_{k=1}^{N} (w'_{kj}) h_k}{\partial w'_{ij}} = h_i$$

.

Implementación de métodos de cálculo

Introducción

- De aquí podemos obtener la forma de actualizar w'_{ij} como

$$w'_{ij}(t+1) = w'_{ij}(t) - \eta e_j h_i$$

ó

$$v'_{p_j}(t+1) = v'_{p_j}(t) - \eta e_j h, \quad \forall\ 1 \leq j \leq |V|$$

donde η es la tasa de aprendizaje $(\eta > 0)$ y v'_{p_j} es la columna j de W' y lo denominamos en vector de salida para la palabra p_j.

Implementación de métodos de cálculo

Introducción

- Fijarse que j es un índice sobre las $|V|$ unidades de salida.
- Cuando $j \neq j^*$, entonces $e_j = y_j$ y la regla de actualización alejará el valor v'_{p_j} del valor de v_{p_l} (recordar que h es v_{p_l}).
- Cuando $j = j^*$, entonces $e_j = y_j - 1$. En este caso, si y_j está cerca de 1, la regla de actualización no introducirá un cambio apreciable en v'_{p_j}.
  Si en cambio, $y_j - 1$ es significativo, la regla de actualización acercará el valor v'_{p_j} al valor de v_{p_l}.

Implementación de métodos de cálculo

Introducción

- Fijarse que j es un índice sobre las $|V|$ unidades de salida.
- Cuando $j \neq j^*$, entonces $e_j = y_j$ y la regla de actualización alejará el valor v'_{p_j} del valor de v_{p_l} (recordar que h es v_{p_l}).
- Cuando $j = j^*$, entonces $e_j = y_j - 1$. En este caso, si y_j está cerca de 1, la regla de actualización no introducirá un cambio apreciable en v'_{p_j}.
  Si en cambio, $y_j - 1$ es significativo, la regla de actualización acercará el valor v'_{p_j} al valor de v_{p_l}.

Implementación de métodos de cálculo

Introducción

- Fijarse que j es un índice sobre las $|V|$ unidades de salida.
- Cuando $j \neq j^*$, entonces $e_j = y_j$ y la regla de actualización alejará el valor v'_{p_j} del valor de v_{p_l} (recordar que h es v_{p_l}).
- Cuando $j = j^*$, entonces $e_j = y_j - 1$. En este caso, si y_j está cerca de 1, la regla de actualización no introducirá un cambio apreciable en v'_{p_j}.
  Si en cambio, $y_j - 1$ es significativo, la regla de actualización acercará el valor v'_{p_j} al valor de v_{p_l}.

Implementación de métodos de cálculo

Introducción

- Para calcular la actualización de los pesos que están entre la entrada y la capa oculta derivemos primero E respecto a h_i

$$\frac{\partial E}{\partial h_i} = \sum_{j=1}^{|V|} \frac{\partial E}{\partial u_j} \frac{\partial u_j}{\partial h_i} = \sum_{j=1}^{|V|} e_j w'_{ij} = EH_i$$

donde h_i es el estado de activación de la unidad i de la capa oculta, u_j es el estado de excitación de la unidad j de la salida y $e_j = y_j - t_j$ es el error sobre la unidad j en la salida.

Implementación de métodos de cálculo

Introducción

EH_i es un elemento del vector EH cuya dimensión es $N \times 1$. Según hemos definido a EH_i, lo podemos escribir como

$$w'_{i,1}e_1 + w'_{i,2}e_2 + \ldots + w'_{i,|V|}e_{|V|}.$$

Si escribimos el vector EH completo tenemos

$$\begin{pmatrix} w'_{1,1}e_1 + w'_{1,2}e_2 + \ldots + w'_{1,|V|}e_{|V|} \\ w'_{2,1}e_1 + w'_{2,2}e_2 + \ldots + w'_{2,|V|}e_{|V|} \\ \vdots \\ w'_{N,1}e_1 + w'_{N,2}e_2 + \ldots + w'_{N,|V|}e_{|V|} \end{pmatrix}.$$

Implementación de métodos de cálculo

Introducción

- Observamos que la primer columna $w'_{.,1}$ de W' está siendo multiplicada por e_1, la segunda $w'_{.,2}$ por e_2, y así.
- Por lo tanto, podemos considerar a EH como la suma de todos los vectores de salida v'_j ($v'_j = w'_{.,j}$), cada uno ponderado por el error e_j en la salida.

Atención

Detengámonos un instante aquí.

Implementación de métodos de cálculo

Introducción

Además, sea e el vector cuyas componentes son e_i donde $1 \leq i \leq |V|$, podemos expresar a EH como

$$EH = W'e$$

donde $W' \in \mathbb{R}^{N \times |V|}$,
$e \in \mathbb{R}^{|V| \times 1}$ y
$EH \in \mathbb{R}^{N \times 1}$.

Implementación de métodos de cálculo

Introducción

- Tomando en cuenta que $h_i = \sum_{k=1}^{|V|} x_k w_{ki}$ derivemos ahora E respecto a w_{ki}, esto es

$$\frac{\partial E}{\partial w_{ki}} = \frac{\partial E}{\partial h_i}\frac{\partial h_i}{\partial w_{ki}} = EH_i x_k.$$

- Recordar que $x \in \mathbb{R}^{|V|\times 1}$.

Implementación de métodos de cálculo

Introducción

- Tomando en cuenta que $h_i = \sum_{k=1}^{|V|} x_k w_{ki}$ derivemos ahora E respecto a w_{ki}, esto es

$$\frac{\partial E}{\partial w_{ki}} = \frac{\partial E}{\partial h_i} \frac{\partial h_i}{\partial w_{ki}} = EH_i x_k.$$

- Recordar que $x \in \mathbb{R}^{|V| \times 1}$.

Implementación de métodos de cálculo

Introducción

Si lo expresamos matricialmente, en vez de derivar respecto a w_{ki}, derivemos respecto de W.
Para eso tendremos en cuenta que $\frac{\partial E}{\partial w_{ki}} = EH_i x_k$ así que

$$\frac{\partial E}{\partial W} = \begin{pmatrix} EH_1x_1 & EH_2x_1 & \dots & EH_Nx_1 \\ EH_1x_2 & EH_2x_2 & \dots & EH_Nx_2 \\ \dots & & & \\ EH_1x_{|V|} & EH_2x_{|V|} & \dots & EH_Nx_{|V|} \end{pmatrix}$$

que es exactamente $EH^t x$, es decir

$$\frac{\partial E}{\partial W} = EH^t x.$$

Implementación de métodos de cálculo

Introducción

- Como x es una representación *one-hot*, solo uno de sus elementos será distinto de 0 y por lo tanto

$$W^{\text{nuevo}} = W^{\text{anterior}} - \eta \frac{\partial E}{\partial W}$$

no es necesario calcularlo sino solo

$$W_{l,.}(\text{nuevo}) = W_{l,.}(\text{anterior}) - \eta E H^t_{l,*}$$

ya que el resto de los elementos de $\frac{\partial E}{\partial W}$ son 0.

Implementación de métodos de cálculo

Introducción

- Dado que la fila I de W es v_{p_I} nos queda que

$$v_{p_I}(\text{nuevo}) = v_{p_I}(\text{anterior}) - \eta E H^t_{I,*}.$$

Implementación de métodos de cálculo

Introducción

- Como habíamos mencionado, EH es la suma de todos los vectores de salida v_i' ponderados por el error de predicción $e_i = y_i - t_j$.
- Fijarse, entonces, que la regla de actualización nos indica que se le va a sumar a cada vector de entrada v una porción de cada vector de salida v' pesado por su error.

Implementación de métodos de cálculo

Introducción

- Como habíamos mencionado, EH es la suma de todos los vectores de salida v_i' ponderados por el error de predicción $e_i = y_i - t_j$.
- Fijarse, entonces, que la regla de actualización nos indica que se le va a sumar a cada vector de entrada v una porción de cada vector de salida v' pesado por su error.

Implementación de métodos de cálculo

Introducción

- Si la palabra siguiente de p_l es p_j, entonces esperamos un 1 en la posición j de la salida. Si y_j es 'pequeña', entonces e_j será un valor 'grande' negativo y en EH pesará el valor de v'_j.
- Por lo tanto, como $\eta EH^t_{l,*}$ está restando, la regla de actualización $v_{p_l}(\text{nuevo}) = v_{p_l}(\text{anterior}) - \eta EH^t_{l,*}$ acercará a v_l hacia v'_j.

Implementación de métodos de cálculo

Introducción

- Si la palabra siguiente de p_l es p_j, entonces esperamos un 1 en la posición j de la salida. Si y_j es 'pequeña', entonces e_j será un valor 'grande' negativo y en EH pesará el valor de v'_j.
- Por lo tanto, como $\eta EH^t_{l,*}$ está restando, la regla de actualización $v_{p_l}(\text{nuevo}) = v_{p_l}(\text{anterior}) - \eta EH^t_{l,*}$ acercará a v_l hacia v'_j.

Implementación de métodos de cálculo

Introducción

- Si la palabra siguiente de p_l no es p_j, entonces esperamos un 0 en la posición j de la salida. Si y_j es 'grande', entonces e_j será un valor 'grande' positivo y en EH pesará el valor de v'_j.
- Por lo tanto, como ηEH^t está restando, la regla de actualización $v_{p_l}(\text{nuevo}) = v_{p_l}(\text{anterior}) - \eta EH^t$ alejará a v_l de v'_j.

Implementación de métodos de cálculo

Introducción

- Si la palabra siguiente de p_l no es p_j, entonces esperamos un 0 en la posición j de la salida. Si y_j es 'grande', entonces e_j será un valor 'grande' positivo y en EH pesará el valor de v'_j.
- Por lo tanto, como ηEH^t está restando, la regla de actualización $v_{p_l}(\text{nuevo}) = v_{p_l}(\text{anterior}) - \eta EH^t$ alejará a v_l de v'_j.

Implementación de métodos de cálculo

Introducción

Resumiendo:

- Dado un par de palabras p_I y p_O donde p_O está en el contexto de p_I (en este caso, es la siguiente), la regla de actualización para W' es

$$w'_{ij}(\text{nuevo}) = w'_{ij}(\text{anterior}) - \eta e_j h_i$$

donde e_j es $y_j - 1$ si $j = O$ e y_j en otro caso.

- La regla de actualización de W es

$$W_{I,.}(\text{nuevo}) = W_{I,.}(\text{anterior}) - \eta EH^t_{I,*}$$

donde $EH = W'e$ y e es el vector de los e_j con $1 \leq j \leq |V|$.

Implementación de métodos de cálculo

Introducción

Resumiendo:

- Dado un par de palabras p_I y p_O donde p_O está en el contexto de p_I (en este caso, es la siguiente), la regla de actualización para W' es
$$w'_{ij}(\text{nuevo}) = w'_{ij}(\text{anterior}) - \eta e_j h_i$$
donde e_j es $y_j - 1$ si $j = O$ e y_j en otro caso.
- La regla de actualización de W es
$$W_{I,.}(\text{nuevo}) = W_{I,.}(\text{anterior}) - \eta EH^t_{I,*}$$
donde $EH = W'e$ y e es el vector de los e_j con $1 \leq j \leq |V|$.

Implementación de métodos de cálculo

CBOW

- Si en vez de tomar un contexto de 1 palabra tomamos C palabras podemos usar una red neuronal artificial donde en vez de 'copiar' la fila $W_{l,.}$ de la matriz W a h, h valdrá el promedio de las filas de W que corresponden a los índices de las palabras en el contexto.
- Este método se denomina *CBOW*, acrónimo del término en inglés *Continuos bag of words*.

Implementación de métodos de cálculo

CBOW

- Si en vez de tomar un contexto de 1 palabra tomamos C palabras podemos usar una red neuronal artificial donde en vez de 'copiar' la fila $W_{l,.}$ de la matriz W a h, h valdrá el promedio de las filas de W que corresponden a los índices de las palabras en el contexto.
- Este método se denomina *CBOW*, acrónimo del término en inglés *Continuos bag of words*.

Implementación de métodos de cálculo

CBOW

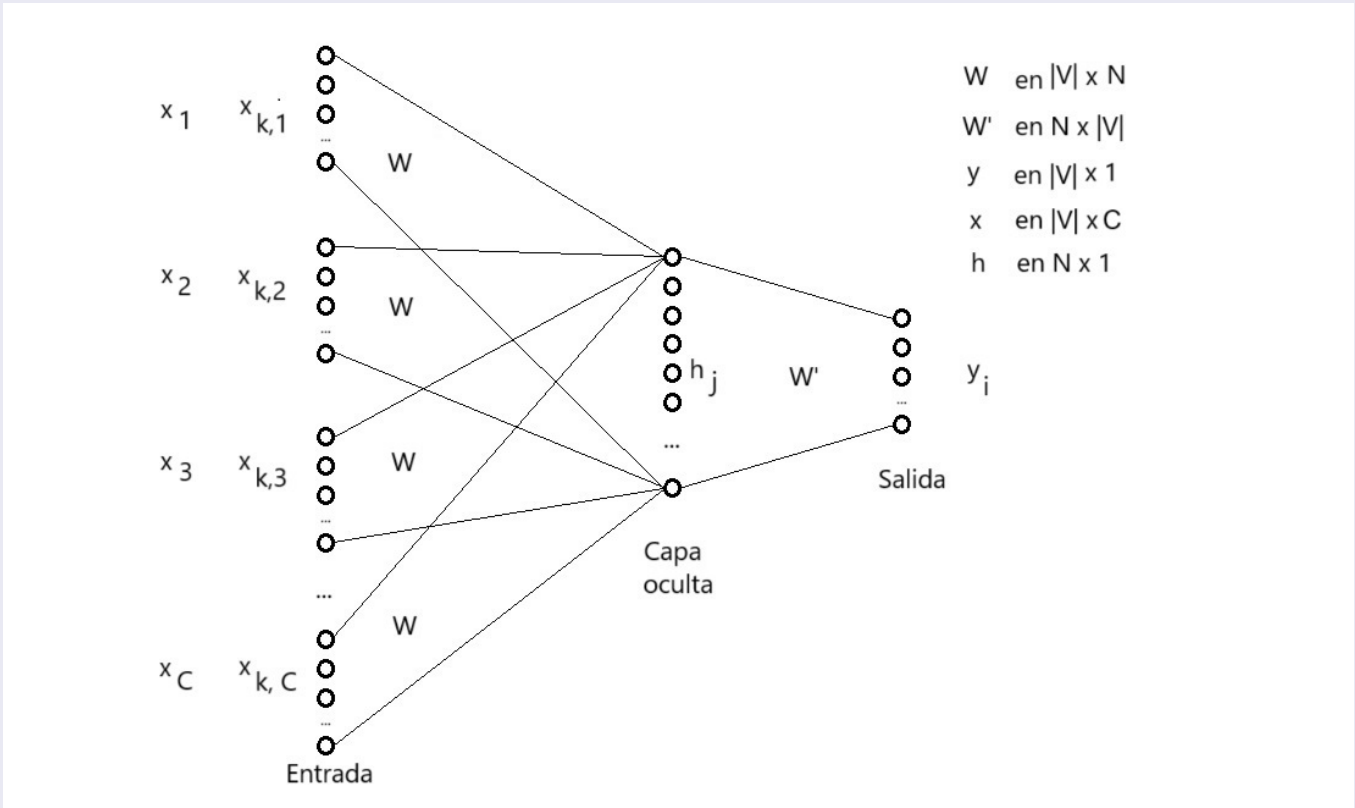
- Esto es

$$h = \frac{1}{C} W^t (x_1 + x_2 + ... + x_C) = \frac{1}{C} (v_{p_1} + v_{p_2} + ... + v_{p_C})$$

donde x_1 es la representación *one-hot* de la primer palabra en el contexto, x_2 de la segunda y así hasta la Cta palabra y
v_{p_1} es la representación contextual de la primer palabra cuya representación *one-hot* es x_1 y además, v_{p_i} es la fila i de W donde i es el índice de la palabra p_i en V.

Implementación de métodos de cálculo

Arquitectura del perceptron multicapa utilizado



Implementación de métodos de cálculo

CBOW

- Ahora, definimos la función de pérdida como

$$E = -\log p(p_O / p_{I,1}, p_{I,2}, \ldots, p_{I,C})$$

$$E = -u_{j^*} + \log \sum_{j'=1}^{|V|} \exp u_{j'}$$

que escrita en función de W' y h resulta en

$$E = -W'_{.,j^*} h + \log \sum_{j'=1}^{|V|} \exp\left(W'_{.,j'} h\right)$$

o considerando que los vectores columnas de W' son los vectores de salida v'

$$E = -v'_{j^*} h + \log \sum_{j'=1}^{|V|} \exp\left(v'_{j'} h\right).$$

Implementación de métodos de cálculo

CBOW

- Si derivamos E respecto a w'_{ij} podemos obtener la regla de actualización

$$w'_{ij}(\text{nuevo}) = w'_{ij}(\text{anterior}) - \eta e_j h_i.$$

En forma vectorial

$$w'_{\cdot,j}(\text{nuevo}) = w'_{\cdot,j}(\text{anterior}) - \eta e_j h$$

o considerando los vectores columnas de W' como los vectores de salida v'

$$v'_j(\text{nuevo}) = v'_j(\text{anterior}) - \eta e_j h.$$

Implementación de métodos de cálculo

CBOW

- No es de extrañar que nos dé igual que el caso anterior donde $C = 1$ (contexto de una sola palabra) ya que en este caso $C > 1$ lo único que se modifica es la forma de calcular h.
- Fijarse que la regla de actualización de la lámina anterior indica que hay que aplicar dicha regla para cada j, $1 \leq j \leq |V|$.

Implementación de métodos de cálculo

CBOW

- No es de extrañar que nos dé igual que el caso anterior donde $C = 1$ (contexto de una sola palabra) ya que en este caso $C > 1$ lo único que se modifica es la forma de calcular h.
- Fijarse que la regla de actualización de la lámina anterior indica que hay que aplicar dicha regla para cada j, $1 \leq j \leq |V|$.

Implementación de métodos de cálculo

CBOW

- Para la regla de actualización de W debemos derivar E respecto W lo cual es similar al caso anterior:

$$\frac{\partial E}{\partial w_{ki}} = \frac{1}{C} EH_i \sum_{c=1}^{C} x_{k,c}$$

excepto porque aparece el factor $\frac{1}{C}$ ya que

$$h_i = \frac{1}{C} \sum_{c=1}^{C} \sum_{k=1}^{|V|} x_{k,c} w_{ki}.$$

Implementación de métodos de cálculo

CBOW

- Recordar que $EH = W'e$ y e es el vector de los e_j, con $1 \leq j \leq |V|$ y

$$e_j = \begin{cases} y_j - 1 & \text{si } j = O, \\ y_j & \text{en otro caso.} \end{cases}$$

Implementación de métodos de cálculo

CBOW

- Vectorialmente

$$W_{Ic,.}(\text{nuevo}) = W_{Ic,.}(\text{anterior}) - \eta \frac{1}{C} EH^t$$

para cada palabra Ic en el contexto, con $1 \leq c \leq C$ y donde W_{Ic} es la fila en W correspondiente a la palabra Ic.

- Teniendo en cuenta que cada fila de W contiene la representación contextual de cada palabra

$$v_{Ic}(\text{nuevo}) = v_{Ic}(\text{anterior}) - \eta \frac{1}{C} EH^t.$$

Implementación de métodos de cálculo

CBOW

- Vectorialmente

$$W_{Ic,.}(\text{nuevo}) = W_{Ic,.}(\text{anterior}) - \eta \frac{1}{C} EH^t$$

para cada palabra Ic en el contexto, con $1 \leq c \leq C$ y donde W_{Ic} es la fila en W correspondiente a la palabra Ic.

- Teniendo en cuenta que cada fila de W contiene la representación contextual de cada palabra

$$v_{Ic}(\text{nuevo}) = v_{Ic}(\text{anterior}) - \eta \frac{1}{C} EH^t.$$

Implementación de métodos de cálculo

CBOW

Resumiendo:

- Dado un contexto de C palabras con representaciones *one-hot* x_{I_c}, la regla de actualización para W' es

$$w'_{\cdot,j}(\text{nuevo}) = w'_{\cdot,j}(\text{anterior}) - \eta e_j h$$

donde

$$e_j = \begin{cases} y_j - 1 & \text{si } j = O, \\ y_j & \text{en otro caso.} \end{cases}$$

Implementación de métodos de cálculo

CBOW

Resumiendo:

- La regla de actualización de W es

$$W_{Ic,.}(\text{nuevo}) = W_{Ic,.}(\text{anterior}) - \eta \frac{1}{C} EH^t$$

para cada palabra Ic con $1 \leq c \leq C$ y
donde $EH = W'e$ y e es el vector de los e_j, con
$1 \leq j \leq |V|$.

Implementación de métodos de cálculo

Skip-gram

- Hasta ahora, hemos visto cómo **a partir de un contexto** podemos **predecir la palabra central** (podríamos predecir, la primera, la última, la segunda, etc).
- Eso nos permite encontrar la codificación por contexto de cada una de las palabras del diccionario V en las filas de la matriz W.

Implementación de métodos de cálculo

Skip-gram

- Hasta ahora, hemos visto cómo **a partir de un contexto** podemos **predecir la palabra central** (podríamos predecir, la primera, la última, la segunda, etc).
- Eso nos permite encontrar la codificación por contexto de cada una de las palabras del diccionario V en las filas de la matriz W.

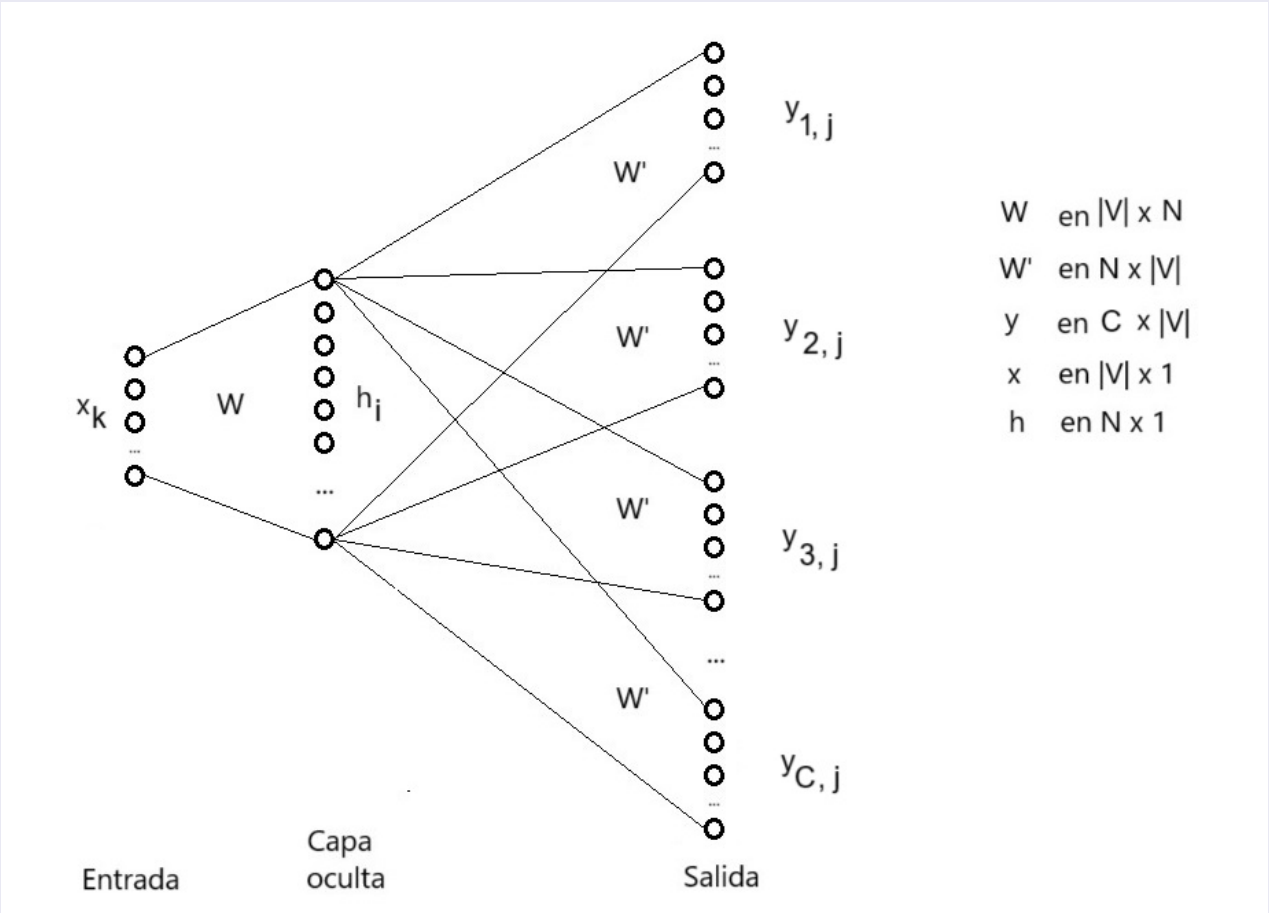
Implementación de métodos de cálculo

Skip-gram

- Ahora veremos un método que tiene muchas similitudes a *CBOW* pero varía en el hecho que la **entrada de la red es una única palabra** y lo que se intenta **predecir en la salida es su contexto**.

Implementación de métodos de cálculo

Skip-gram



Implementación de métodos de cálculo

Skip-gram

- De acuerdo a la arquitectura mostrada y considerando que x es la representación *one-hot* de la palabra p_I, h se puede calcular como

$$h = W^t x = W^t_{.,I}$$

donde la fila I transpuesta de W, $W^t_{.,I}$ es v_{p_I} que denominamos vector de entrada (nuestra representación contextual de la palabra p_I y es la que la red debe aprender) e I es el índice de palabra en el diccionario V.

Implementación de métodos de cálculo

Skip-gram

- Por otro lado, se puede observar C paneles de salida, uno por cada palabra del contexto.
- Cada panel tiene dimensión $|V|$ correspondiendo a cada representación *one-hot* de las palabras en el contexto de dimensión C.
- De este modo, la salida de cada unidad de cada panel se notará como $y_{c,j}$ donde $1 \leq c \leq C$ y $1 \leq j \leq |V|$.

Implementación de métodos de cálculo

Skip-gram

- Por otro lado, se puede observar C paneles de salida, uno por cada palabra del contexto.
- Cada panel tiene dimensión $|V|$ correspondiendo a cada representación *one-hot* de las palabras en el contexto de dimensión C.
- De este modo, la salida de cada unidad de cada panel se notará como $y_{c,j}$ donde $1 \leq c \leq C$ y $1 \leq j \leq |V|$.

Implementación de métodos de cálculo

Skip-gram

- Por otro lado, se puede observar C paneles de salida, uno por cada palabra del contexto.
- Cada panel tiene dimensión $|V|$ correspondiendo a cada representación *one-hot* de las palabras en el contexto de dimensión C.
- De este modo, la salida de cada unidad de cada panel se notará como $y_{c,j}$ donde $1 \leq c \leq C$ y $1 \leq j \leq |V|$.

Implementación de métodos de cálculo

Skip-gram

- El estado de excitación de cada unidad de salida en cada panel tendrá una notación similar $u_{c,j}$.
- La matriz de pesos W' será la misma para cada panel, por lo tanto

$$u_{c,j} = (W'_{*,j})^t h$$

  donde simplemente notamos u_j en vez de $u_{c,j}$.
- Se puede observar que, el estado de excitación de cada unidad j en cualquier panel c es la misma ya que todos los paneles comparten W'.

Implementación de métodos de cálculo

Skip-gram

- El estado de excitación de cada unidad de salida en cada panel tendrá una notación similar $u_{c,j}$.
- La matriz de pesos W' será la misma para cada panel, por lo tanto

$$u_{c,j} = (W'_{*,j})^t h$$

  donde simplemente notamos u_j en vez de $u_{c,j}$.
- Se puede observar que, el estado de excitación de cada unidad j en cualquier panel c es la misma ya que todos los paneles comparten W'.

Implementación de métodos de cálculo

Skip-gram

- El estado de excitación de cada unidad de salida en cada panel tendrá una notación similar $u_{c,j}$.
- La matriz de pesos W' será la misma para cada panel, por lo tanto

$$u_{c,j} = (W'_{*,j})^t h$$

  donde simplemente notamos u_j en vez de $u_{c,j}$.
- Se puede observar que, el estado de excitación de cada unidad j en cualquier panel c es la misma ya que todos los paneles comparten W'.

Implementación de métodos de cálculo

Skip-gram

- Además, los vectores columnas de W' se los denomina vectores de salida, se los nota como v'_{p_j} y también van a ser aprendidos ($1 \leq j \leq |V|$).
- Así,

$$u_j = (v'_{p_j})^t h = (v'_{p_j})^t v^t_{p_I}$$

donde v_{p_I} es el vector de entrada para la palabra p_I y v'_{p_j} es el vector de salida para la palabra p_j.

Implementación de métodos de cálculo

Skip-gram

- Además, los vectores columnas de W' se los denomina vectores de salida, se los nota como v'_{p_j} y también van a ser aprendidos $(1 \leq j \leq |V|)$.
- Así,

$$u_j = (v'_{p_j})^t h = (v'_{p_j})^t v^t_{p_I}$$

donde v_{p_I} es el vector de entrada para la palabra p_I y v'_{p_j} es el vector de salida para la palabra p_j.

Implementación de métodos de cálculo

Skip-gram

- Finalmente, la $P(p_c = p_{O_c}/p_I)$ es

$$P(p_c = p_{O_c}/p_I) = y_{c,j*} = \frac{\exp u_{j*}}{\sum_{j'=1}^{|V|} \exp u_{j'}}$$

que se lee: la probabilidad que en el panel c esté representada la palabra p_{O_c} dada la entrada p_I es igual a $y_{c,j*}$ que es la salida de la soft-max de la unidad $j*$ del panel c y la representación *one-hot* de p_{O_c} tiene un 1 en la posición $j*$.

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- Para actualizar los pesos se plantea una función a minimizar

$$E = -\log P(p_{O_1}, p_{O_2}, ..., p_{O_C}/p_I)$$

- $P(p_{O_1}, p_{O_2}, ..., p_{O_C}/p_I)$ es $P(p_{O_1}/p_I) * P(p_{O_2}/p_I) * ... * P(p_{O_C}/p_I)$ asuminendo que p_{O_1}, p_{O_2}, ..., p_{O_C} son independientes.
- Esto es,

$$P(p_{O_1}, p_{O_2}, ..., p_{O_C}/p_I) = \prod_{c=1}^{C} P(p_{O_c}/p_I)$$

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- Para actualizar los pesos se plantea una función a minimizar

$$E = -\log P(p_{O_1}, p_{O_2}, ..., p_{O_C}/p_I)$$

- $P(p_{O_1}, p_{O_2}, ..., p_{O_C}/p_I)$ es $P(p_{O_1}/p_I) * P(p_{O_2}/p_I) * ... * P(p_{O_C}/p_I)$ asuminendo que p_{O_1}, p_{O_2}, ..., p_{O_C} son independientes.
- Esto es,

$$P(p_{O_1}, p_{O_2}, ..., p_{O_C}/p_I) = \prod_{c=1}^{C} P(p_{O_c}/p_I)$$

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- Para actualizar los pesos se plantea una función a minimizar

$$E = -\log P(p_{O_1}, p_{O_2}, ..., p_{O_C}/p_I)$$

- $P(p_{O_1}, p_{O_2}, ..., p_{O_C}/p_I)$ es
  $P(p_{O_1}/p_I) * P(p_{O_2}/p_I) * ... * P(p_{O_C}/p_I)$
  asuminendo que p_{O_1}, p_{O_2}, ..., p_{O_C} son independientes.
- Esto es,

$$P(p_{O_1}, p_{O_2}, ..., p_{O_C}/p_I) = \prod_{c=1}^{C} P(p_{O_c}/p_I)$$

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- Así podemos escribir E como

$$E = -\log \prod_{c=1}^{C} \frac{\exp\left(u_{c,j_c^*}\right)}{\sum_{j'=1}^{|V|} \exp\left(u_{c,j'}\right)}$$

$$E = -\sum_{c=1}^{C} u_{j_c^*} + C \log \sum_{j'=1}^{|V|} \exp\left(u_{j_c'}\right)$$

donde j_c^* es el índice del panel c (donde la representación *one-hot* del panel c vale 1).

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- Recordar que $u_{c,j_c^*} = u_{j_c^*}$ dado que W' es la misma para todos los paneles c y, por lo tanto $\sum_{j'=1}^{|V|} \exp\left(u_{j'_c}\right)$ vale lo mismo para todos los paneles.

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- Derivando E respecto a $u_{j,c}$ obtenemos:

$$\frac{\partial E}{\partial u_{c,j}} = y_{c,j} - t_{c,j} = e_{c,j}$$

ya que $\frac{\partial(-\sum_{c=1}^{C} u_{j_c^*})}{\partial u_{c,j}} = y_{c,j} - t_{c,j}$

donde

$$t_{c,j} = \begin{cases} 1 & \text{si } u_{c,j} = u_{c,j^*} \text{ y} \\ 0 & \text{en otro caso.} \end{cases}$$

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- Observar que no aparece el factor C dado que estamos derivando respecto al estado de excitación de una unidad de salida en un solo panel c.

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- Por comodidad definimos un vector $|V|$-dimensional EI

$$EI = (EI_1, EI_2, ..., E_{I|V|})$$

donde $EI_j = \sum_{c=1}^{C} e_{c,j}$.

- Para obtener una regla de actualización para W' derivamos a E respecto a w'_{ij}

$$\frac{\partial E}{\partial w'_{ij}} = \sum_{c=1}^{C} \frac{\partial E}{\partial u_{c,j}} \frac{\partial u_{c,j}}{\partial w'_{ij}} = EI_j h_i.$$

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- Por comodidad definimos un vector $|V|$-dimensional EI

$$EI = (EI_1, EI_2, ..., E_{I|V|})$$

donde $EI_j = \sum_{c=1}^{C} e_{c,j}$.

- Para obtener una regla de actualización para W' derivamos a E respecto a w'_{ij}

$$\frac{\partial E}{\partial w'_{ij}} = \sum_{c=1}^{C} \frac{\partial E}{\partial u_{c,j}} \frac{\partial u_{c,j}}{\partial w'_{ij}} = EI_j h_i.$$

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- Esto resulta en

$$w'_{ij}(\text{nuevo}) = w'_{ij}(\text{anterior}) - \eta EI_j h_i$$

o según definimos más arriba

$$v'_{p_j}(\text{nuevo}) = v'_{p_j}(\text{anterior}) - \eta EI_j h.$$

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- La regla de actualización de los pesos de la matriz W es

$$v_{p_I}(\text{nuevo}) = v_{p_I}(\text{anterior}) - \eta EH^t$$

donde $EH_i = \sum_{j=1}^{|V|} EI_j w'_{ij}$.

- Recordar que v_{p_I} es el vector fila de W para la palabra p_I.

Implementación de métodos de cálculo

Skip-gram. Actualización de pesos

- La regla de actualización de los pesos de la matriz W es

$$v_{p_I}(\text{nuevo}) = v_{p_I}(\text{anterior}) - \eta EH^t$$

donde $EH_i = \sum_{j=1}^{|V|} EI_j w'_{ij}$.

- Recordar que v_{p_I} es el vector fila de W para la palabra p_I.

Implementación de métodos de cálculo

Skip-gram. Consideraciones finales

- Dado que la excitación $u_{c,j}$ es la misma $\forall c, 1 \leq c \leq C$, las salidas $y_{c,j}$ serán las mismas también.
- Es decir, el vector y de salida de cada panel es el mismo independientemente del valor de c.
- Entonces, no podemos esperar que identifiquemos la palabra más probable en cada panel ya que todos los paneles mostrarán la misma distribución de probabilidad.

Implementación de métodos de cálculo

Skip-gram. Consideraciones finales

- Dado que la excitación $u_{c,j}$ es la misma $\forall c, 1 \leq c \leq C$, las salidas $y_{c,j}$ serán las mismas también.
- Es decir, el vector y de salida de cada panel es el mismo independientemente del valor de c.
- Entonces, no podemos esperar que identifiquemos la palabra más probable en cada panel ya que todos los paneles mostrarán la misma distribución de probabilidad.

Implementación de métodos de cálculo

Skip-gram. Consideraciones finales

- Dado que la excitación $u_{c,j}$ es la misma $\forall c, 1 \leq c \leq C$, las salidas $y_{c,j}$ serán las mismas también.
- Es decir, el vector y de salida de cada panel es el mismo independientemente del valor de c.
- Entonces, no podemos esperar que identifiquemos la palabra más probable en cada panel ya que todos los paneles mostrarán la misma distribución de probabilidad.

Implementación de métodos de cálculo

Skip-gram. Consideraciones finales

- Dado que
  1. la matriz de pesos W' entre la capa oculta y la salida es compartida por todos los paneles y
  2. el error EI_j se obtiene como la sumatoria de los errores $e_{c,j}$ en cada panel
- la distribución de probabilidad multimodal en la salida (que es la misma para cada panel) mostrará qué palabras son más probables para la única entrada.

Implementación de métodos de cálculo

Skip-gram. Consideraciones finales

- Dado que
  1. la matriz de pesos W' entre la capa oculta y la salida es compartida por todos los paneles y
  2. el error EI_j se obtiene como la sumatoria de los errores $e_{c,j}$ en cada panel
- la distribución de probabilidad multimodal en la salida (que es la misma para cada panel) mostrará qué palabras son más probables para la única entrada.

Implementación de métodos de cálculo

Skip-gram. Consideraciones finales

- Dado que
  1. la matriz de pesos W' entre la capa oculta y la salida es compartida por todos los paneles y
  2. el error EI_j se obtiene como la sumatoria de los errores $e_{c,j}$ en cada panel
- la distribución de probabilidad multimodal en la salida (que es la misma para cada panel) mostrará qué palabras son más probables para la única entrada.

Implementación de métodos de cálculo

Skip-gram. Consideraciones finales

- Dado que
  1. la matriz de pesos W' entre la capa oculta y la salida es compartida por todos los paneles y
  2. el error EI_j se obtiene como la sumatoria de los errores $e_{c,j}$ en cada panel
- la distribución de probabilidad multimodal en la salida (que es la misma para cada panel) mostrará qué palabras son más probables para la única entrada.

Implementación de métodos de cálculo

Skip-gram. Consideraciones finales

- De modo que si la salida tiene, por ejemplo, 4 paneles, las palabras más probables que pueden aparecer en un contexto de la palabra de entrada serán aquellas 4 que tengan mayor probabilidad.
- Esto es, los j_c^* serán aquellos que tengan el mayor valor de y_j en la capa de salida.
- Recordar que los $y_{c,j}$ son los mismos en cada panel y por lo tanto se los puede considerar como una salida única y_j.

Implementación de métodos de cálculo

Skip-gram. Consideraciones finales

- De modo que si la salida tiene, por ejemplo, 4 paneles, las palabras más probables que pueden aparecer en un contexto de la palabra de entrada serán aquellas 4 que tengan mayor probabilidad.
- Esto es, los j_c^* serán aquellos que tengan el mayor valor de y_j en la capa de salida.
- Recordar que los $y_{c,j}$ son los mismos en cada panel y por lo tanto se los puede considerar como una salida única y_j.

Implementación de métodos de cálculo

Skip-gram. Consideraciones finales

- De modo que si la salida tiene, por ejemplo, 4 paneles, las palabras más probables que pueden aparecer en un contexto de la palabra de entrada serán aquellas 4 que tengan mayor probabilidad.
- Esto es, los j_c^* serán aquellos que tengan el mayor valor de y_j en la capa de salida.
- Recordar que los $y_{c,j}$ son los mismos en cada panel y por lo tanto se los puede considerar como una salida única y_j.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Como hemos visto, la actualización de W' conlleva a aplicar la regla de actualización

$$w'_{\cdot,j}(\text{nuevo}) = w'_{\cdot,j}(\text{anterior}) - \eta e_j h$$

para cada j, con $1 \leq j \leq |V|$.

- A medida que el tamaño $|V|$ de V se incrementa, aumenta el costo computacional del proceso.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Como hemos visto, la actualización de W' conlleva a aplicar la regla de actualización

$$w'_{\cdot,j}(\text{nuevo}) = w'_{\cdot,j}(\text{anterior}) - \eta e_j h$$

  para cada j, con $1 \leq j \leq |V|$.
- A medida que el tamaño $|V|$ de V se incrementa, aumenta el costo computacional del proceso.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Una forma de abordar este problema es definir un subconjunto 'pequeño' de palabras de V (que no incluya a p_O) para actualizar a W'.
- Esto es, si $P_{sel} = \{p_{sel_1}, p_{sel_2}, \cdots, p_{sel_{|P_{sel}|}}\}$ es un subconjunto de V seleccionado al azar, diremos que P_{sel} es el conjunto de ejemplos negativos.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Una forma de abordar este problema es definir un subconjunto 'pequeño' de palabras de V (que no incluya a p_O) para actualizar a W'.
- Esto es, si $P_{sel} = \{p_{sel_1}, p_{sel_2}, ..., p_{sel_{|P_{sel}|}}\}$ es un subconjunto de V seleccionado al azar, diremos que P_{sel} es el conjunto de ejemplos negativos.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Cada elemento de P_{sel}, al ser una palabra del diccionario le corresponde una representación *one-hot*.
  Sea $p_{sel_i} \in P_{sel}$, entonces la representación *one-hot* tendrá un 1 en la posición i_{j*}.
- Fijarse que el subíndice i indica a qué palabra nos referimos en P_{sel} mientras que i_{j*} indica en qué posición de la representación *one-hot* de la palabra p_{sel_i} está el valor 1.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Cada elemento de P_{sel}, al ser una palabra del diccionario le corresponde una representación *one-hot*.
  Sea $p_{sel_i} \in P_{sel}$, entonces la representación *one-hot* tendrá un 1 en la posición i_{j*}.
- Fijarse que el subíndice i indica a qué palabra nos referimos en P_{sel} mientras que i_{j*} indica en qué posición de la representación *one-hot* de la palabra p_{sel_i} está el valor 1.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- La función de pérdida para usar esta heurística está definida como

$$E = -\log \sigma((v'_{p_O})^t h) - \sum_{p_j \in P_{sel}} \log \sigma(-(v'_{p_j})^t h)$$

donde $\sigma()$ es la función sigmoidea logística

$$\sigma(x) = \frac{1}{1 + \exp(-x)}.$$

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Para obtener la regla de actualización primero recordemos que

$$\sigma(-x) = 1 - \sigma(x)$$

y

$$\frac{d\sigma(x)}{dx} = \sigma(x)\sigma(-x).$$

- Ahora, por simplicidad en la notación, llamemos u_j a $(v'_{p_j})^t h$ pudiendo expresar E como

$$E = -\log \sigma(u_O) - \sum_{p_j \in P_{sel}} \log \sigma(-u_j)$$

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Para obtener la regla de actualización primero recordemos que

$$\sigma(-x) = 1 - \sigma(x)$$

y

$$\frac{d\sigma(x)}{dx} = \sigma(x)\sigma(-x).$$

- Ahora, por simplicidad en la notación, llamemos u_j a $(v'_{p_j})^t h$ pudiendo expresar E como

$$E = -\log \sigma(u_O) - \sum_{p_j \in P_{sel}} \log \sigma(-u_j)$$

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Derivemos E respecto a u_j.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Si $j = O$ (O corresponde a una de las palabras del panel, es decir positiva)

$$\frac{\partial E}{\partial u_O} = -\frac{1}{\sigma(u_O)}(\sigma(u_O)\sigma(-u_O)) - \sum_{j' \in ind_{P_{sel}}} \frac{1}{\sigma(-u_{j'})}(\sigma(-u_{j'})\sigma(u_{j'}))$$

donde $ind_{P_{sel}}$ es el conjunto de indices de las palabras en P_{sel}.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Dado que p_O no está en P_{sel},
$$\sum_{j' \in ind_{P_{sel}}} \frac{1}{\sigma(-u_{j'})}(\sigma(-u_{j'})\sigma(u_{j'})) = 0$$
ya que j no coincide con ningún j' y por lo tanto la sumatoria es una constante que al derivar es 0.
- Así,
$$\frac{\partial E}{\partial u_O} = -\sigma(-u_O) = -(1 - \sigma(u_O)) = \sigma(u_O) - 1.$$

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Dado que p_O no está en P_{sel},
$$\sum_{j' \in ind_{P_{sel}}} \frac{1}{\sigma(-u_{j'})}(\sigma(-u_{j'})\sigma(u_{j'})) = 0$$
ya que j no coincide con ningún j' y por lo tanto la sumatoria es una constante que al derivar es 0.
- Así,
$$\frac{\partial E}{\partial u_O} = -\sigma(-u_O) = -(1 - \sigma(u_O)) = \sigma(u_O) - 1.$$

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Si $j \neq O$ ($p_j \in P_{sel}$, es decir es un ejemplo negativo)

$$\frac{\partial E}{\partial u_j} = 0 - \sum_{j' \in ind_{P_{sel}}} \frac{1}{\sigma(-u_{j'})}(\sigma(-u_{j'})\sigma(u_{j'})) = \sigma(u_j).$$

- Podemos generalizar $\frac{\partial E}{\partial u_j}$ como

$$\frac{\partial E}{\partial u_j} = \sigma(u_j) - t_j$$

donde $t_j = 1$ si $j = O$ y $t_j = 0$ si $p_j \in P_{sel}$.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Si $j \neq O$ ($p_j \in P_{sel}$, es decir es un ejemplo negativo)

$$\frac{\partial E}{\partial u_j} = 0 - \sum_{j' \in ind_{P_{sel}}} \frac{1}{\sigma(-u_{j'})}(\sigma(-u_{j'})\sigma(u_{j'})) = \sigma(u_j).$$

- Podemos generalizar $\frac{\partial E}{\partial u_j}$ como

$$\frac{\partial E}{\partial u_j} = \sigma(u_j) - t_j$$

donde $t_j = 1$ si $j = O$ y $t_j = 0$ si $p_j \in P_{sel}$.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Si j no corresponde ni a una de las palabras del panel ni a una de las palabras de P_{sel}, entonces

$$\frac{\partial E}{\partial u_j} = 0$$

pues E está definida sobre las palabras del panel y las que están en P_{sel} y por lo tanto no tiene sentido actualizar la columna j de W'.

- De aquí, la reducción del costo computacional y ventaja de usar este método.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Si j no corresponde ni a una de las palabras del panel ni a una de las palabras de P_{sel}, entonces

$$\frac{\partial E}{\partial u_j} = 0$$

  pues E está definida sobre las palabras del panel y las que están en P_{sel} y por lo tanto no tiene sentido actualizar la columna j de W'.
- De aquí, la reducción del costo computacional y ventaja de usar este método.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Para obtener la regla de actualización de W' podemos derivar E respecto a la columna de W' correspondiente a p_j

$$\frac{\partial E}{\partial v'_{p_j}} = \frac{\partial E}{u_j}\frac{\partial u_j}{\partial v'_{p_j}} = (\sigma(u_j) - t_j)h$$

  ya que, como habíamos notado $u_j = (v'_{p_j})^t h$.

- Luego, la regla de actualización de v'_{p_j} es

$$v'_{p_j}(\text{nuevo}) = v'_{p_j}(\text{anterior}) - \eta(\sigma(u_j) - t_j)h.$$

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Para obtener la regla de actualización de W' podemos derivar E respecto a la columna de W' correspondiente a p_j

$$\frac{\partial E}{\partial v'_{p_j}} = \frac{\partial E}{u_j}\frac{\partial u_j}{\partial v'_{p_j}} = (\sigma(u_j) - t_j)h$$

  ya que, como habíamos notado $u_j = (v'_{p_j})^t h$.
- Luego, la regla de actualización de v'_{p_j} es

$$v'_{p_j}(\text{nuevo}) = v'_{p_j}(\text{anterior}) - \eta(\sigma(u_j) - t_j)h.$$

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Para calcular $\frac{\partial E}{\partial W}$ podemos recurrir a la fórmula obtenida para actualizar los pesos W en *Skip-gram* (sin muestreo de ejemplos negativos)

$$W_{Ic,.}(\text{nuevo}) = W_{Ic,.}(\text{anterior}) - \eta EH^t$$

pero como estamos usando otra función de activación en la salida y un conjunto de palabras como ejemplos negativos, cambiará la definición de EH.

- Recordemos que EH la definimos como $\frac{\partial E}{\partial h}$.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Para calcular $\frac{\partial E}{\partial W}$ podemos recurrir a la fórmula obtenida para actualizar los pesos W en *Skip-gram* (sin muestreo de ejemplos negativos)

$$W_{Ic,.}(\text{nuevo}) = W_{Ic,.}(\text{anterior}) - \eta EH^t$$

pero como estamos usando otra función de activación en la salida y un conjunto de palabras como ejemplos negativos, cambiará la definición de EH.

- Recordemos que EH la definimos como $\frac{\partial E}{\partial h}$.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Teniendo en cuenta el cambio de la función de activación y la actualización de los parámetros (W y W') basándonos solo en P_{sel} podemos calcular EH como:

$$EH = \frac{\partial E}{\partial h} = \sum_{p_j \in \{p_O\} \cup P_{sel}} \frac{\partial E}{\partial u_j} \frac{\partial u_j}{\partial h} =$$

$$\frac{\partial E}{\partial h} = \sum_{p_j \in \{p_O\} \cup P_{sel}} (\sigma(u_j) - t_j) v'_{p_j}$$

ya que $u_j = (v'_{p_j})^t h$.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- La idea de considerar un muestreo de casos negativos en lugar de considerar todas las palabras del diccionario reduce considerablemente los tiempos de procesamiento.
- Considerar un cardinal del conjunto de muestreo de casos negativos P_{sel} entre 5 y 20 puede ser adecuado para corpus de datos (conjunto de documentos con que se entrena) 'pequeños' mientras que 2 a 5 puede ser útil para corpus 'grandes' (Mikolov et al. 2013, NIPS).

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- La idea de considerar un muestreo de casos negativos en lugar de considerar todas las palabras del diccionario reduce considerablemente los tiempos de procesamiento.
- Considerar un cardinal del conjunto de muestreo de casos negativos P_{sel} entre 5 y 20 puede ser adecuado para corpus de datos (conjunto de documentos con que se entrena) 'pequeños' mientras que 2 a 5 puede ser útil para corpus 'grandes' (Mikolov et al. 2013, NIPS).

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- La selección de palabras que componen el P_{sel} requiere tomar $|P_{sel}|$ palabras de una distribución.
- Una forma es escoger las palabras al azar teniendo en cuenta la distribución unigrama $U(p)$ la cual puede ser obtenida a partir de las frecuencias relativas de las palabras p del diccionario. Mikolov et al. proponen elevar a las $3/4$ y dividir por Z:

$$U'(p) = \frac{U(p)^{3/4}}{Z}$$

. donde Z es una constante fijada experimentalmente.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- La selección de palabras que componen el P_{sel} requiere tomar $|P_{sel}|$ palabras de una distribución.
- Una forma es escoger las palabras al azar teniendo en cuenta la distribución unigrama $U(p)$ la cual puede ser obtenida a partir de las frecuencias relativas de las palabras p del diccionario. Mikolov et al. proponen elevar a las $3/4$ y dividir por Z:

$$U'(p) = \frac{U(p)^{3/4}}{Z}$$

. donde Z es una constante fijada experimentalmente.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Al elevar a las 3/4 la probabilidades más 'pequeñas' se incrementan más que lo se incrementan las probabilidades más 'grandes'.
- Eso favorecería la posibilidad de usar palabras en el muestreo negativo que tengan baja probabilidad en la distribución unigrama.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Al elevar a las 3/4 la probabilidades más 'pequeñas' se incrementan más que lo se incrementan las probabilidades más 'grandes'.
- Eso favorecería la posibilidad de usar palabras en el muestreo negativo que tengan baja probabilidad en la distribución unigrama.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Sin embargo, el concepto de muestreo negativo tiene otras interpretaciones.
- En el modelo *skip-gram* que busca la representación contextual de las palabras mediante una red neuronal artificial cuya entrada es una representación *one-hot* de una palabra y la salida es la representación *one-hot* de varias palabras que corresponden al contexto de la entrada.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Sin embargo, el concepto de muestreo negativo tiene otras interpretaciones.
- En el modelo *skip-gram* que busca la representación contextual de las palabras mediante una red neuronal artificial cuya entrada es una representación *one-hot* de una palabra y la salida es la representación *one-hot* de varias palabras que corresponden al contexto de la entrada.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- En dicho modelo, el muestreo de negativos puede ser obtenido a partir de las palabras que están por fuera del contexto de la entrada pero aún así cerca de ella.

(ref: https://www.tensorflow.org/text/tutorials/word2vec)

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Por ejemplo,

  'En la espesura de la niebla, la embarcación navegaba cautelosamente durante la noche evitando que su quilla quedara atascada entre la vegetación submarina del río'

- Sea la palabra de entrada 'quilla' y con un contexto de tamaño 3 (3 a la derecha y 3 a la izquierda) una entrada positiva para el modelo *skip-gram* es

  {quilla, {evitando, que, su, quedara, atascada, entre} }

  mientras que uno negativo es

  {quilla, {durante, la, noche, la, vegetación, submarina} }.

Implementación de métodos de cálculo

Reducción de la complejidad computacional

- Por ejemplo,

  'En la espesura de la niebla, la embarcación navegaba cautelosamente durante la noche evitando que su quilla quedara atascada entre la vegetación submarina del río'

- Sea la palabra de entrada 'quilla' y con un contexto de tamaño 3 (3 a la derecha y 3 a la izquierda) una entrada positiva para el modelo *skip-gram* es

  {quilla, {evitando, que, su, quedara, atascada, entre} }

  mientras que uno negativo es

  {quilla, {durante, la, noche, la, vegetación, submarina} }.