Aprendizaje automático avanzado
Fragmentación de texto

Juan Miguel Santos

Laboratorio de investigación y desarrollo experimental en computación (LIDEC)
Universidad Nacional de Hurlingham

(3 de septiembre de 2026)

Fragmentación de texto

Introducción

- La posibilidad de procesar texto en PLN radica en la representación del mismo en forma numérica.
- Una forma que vimos de hacerlo es codificando las palabras (y signos de puntuación) mediante vectores en los reales.

Fragmentación de texto

Introducción

- Con métodos tales como CBOW o Skip-gram, podemos obtener representaciones contextuales de las palabras presentes en un corpus.
- Dichos métodos se basan en aprender dichas representaciones mediante perceptrones multicapa usando representaciones de las entradas y las salidas del tipo *one-hot*.

Fragmentación de texto

Introducción

- Como hemos visto, la dimensión de representación *one-hot* produce matrices de pesos sinápticos de alta dimensionalidad ($|V| \times N$).
- Una alternativa podría ser representar letras y signos de puntuación en vez de palabras.
- En ese caso, la representación *one-hot* disminuiría drásticamente su dimensión.
- Esto es, que nuestro vocabulario no tenga, por ejemplo, más de 64 entradas.

Fragmentación de texto

Introducción

- Sin embargo, este ahorro en la dimensión de representación *one-hot* desdibuja el objetivo de los métodos de codificación que buscan asociar representaciones que "refieren a lo mismo" o "tienen similar significado" como sí se puede hacer con las palabras.

Fragmentación de texto

Introducción

- Los métodos de fragmentación (o tokenización, neologismo de la palabra inglesa *tokenization*) buscan un camino intermedio entre ambos extremos.
- La idea es fragmentar el texto en fragmentos de tal forma que concatenados puedan formar diferentes palabras e incluso nuevas que no estaban presentes en el vocabulario.

Fragmentación de texto

Introducción

- Esto trae como ventaja que:
  1. la cantidad de dichos fragmentos puede ser apreciablemente menor que la cantidad de palabras
  2. que nuevas palabras, que no figuraban en el corpus de entrenamiento, puedan ser interpretadas.

Fragmentación de texto

Introducción

- Cuando usando un modelo de lenguaje aparece un *token* (o secuencia de *tokens*) que no están presentes en el vocabulario se representan usualmente mediante el *token* $< UNK >$.
- Aunque hay diferentes estrategias para tratar con esta situación (por ejemplo, en el contexto de un traductor) la posibilidad de fragmentar el texto en fragmentos más pequeños que las palabras, ha mostrado empíricamente superar dichas estrategias.

Fragmentación de texto

BPE

- El método *Byte Pair Encoding* o BPE fue originalmente pensado como un método de compresión pero en 2015 fue adaptado por Sennrich, Haddow y Birch para cumplir con el propósito que comentamos más arriba.
- La idea del BPE es comenzar con un vocabulario compuesto sólo de los signos elementales que, en el caso de PLN, son las letras del alfabeto más algunos signos de puntuación.

Fragmentación de texto

BPE

- De esta forma, cada *token* será un signo del vocabulario.
- A partir de dicho vocabulario, se recorre el corpus midiendo la frecuencia relativa de los pares de *tokens* consecutivos.
- Luego, se incorpora el par más frecuente al vocabulario. (Fijarse que, ahora los *tokens* pueden estar formados por más de un signo.)
- Este proceso se vuelve a realizar una cantidad de veces definida de antemano o hasta que el vocabulario tenga la cantidad de entradas deseadas.

Fragmentación de texto

Ejemplo de aplicación de BPE

- Consideremos el siguiente ejemplo:
  Corpus = "Mediodía soleado de un día con sol."
- El vocabulario de signos a partir de este corpus es:
  {m, e, d, i, o, í, a, _, s, l, u, n, c, .} con 14 entradas.
- La fragmentación del corpus resulta en
  {m, e, d, i, o, d, í, a, _, s, o, l, e, a, d, o, _, d, e, _, u, n, _, d, í, a, _, c, o, n, _, s, o, l, .} de 35 *tokens*.

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- **Paso 1**
  Frecuencia de pares
  {me: 1, ed: 1, di: 1, io: 1, od: 1, dí: 2,
  ía: 2, a_: 2, _s: 2, so: 2, ol: 2, le: 1, ea: 1, ad: 1,
  do: 1, o_: 1, _d: 1, de: 1, e_: 1, _u: 1, un: 1,
  n_: 2, _d: 1, _c: 1, co: 1, on: 1, l.: 1}
- Tomamos "dí" como el par más frecuente.

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- Tomamos "dí" como el par más frecuente.
- Vocabulario resultante:
  {m, e, d, i, o, í, a, _, s, l, u, n, c, ., dí} con 15 entradas
- Fragmentación:
  {m, e, d, i, o, dí, a, _, s, o, l, e, a, d, o, _, d, e, _, u, n, _, dí, a, _, c, o, n, _, s, o, l, .} de 33 *tokens*.

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- **Paso 2**

  Frecuencia de pares

  {me: 1, ed: 1, di: 1, io: 1, odí: 1, día: 2, a_: 2,
  _s: 2, so: 2, ol: 2, le: 1, ea: 1, ad: 1, do: 1,
  o_: 1, _d: 1, de: 1, e_: 1, _u: 1, un: 1,
  n_: 2, _dí: 1, _c: 1, co: 1, on: 1, l.: 1}

- Tomamos "día": 2

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- Tomamos "día": 2
- Vocabulario
  {m, e, d, i, o, í, a, _, s, l, u, n, c, ., dí, día}, 16 entradas
- Fragmentación
  {m, e, d, i, o, día, _, s, o, l, e, a, d, o, _, d, e, _, u, n, _, día, _, c, o, n, _, s, o, l, .} de 31 *tokens*.

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- **Paso 3** Frecuencia de pares:
  {me: 1, ed: 1, di: 1, io: 1, odía: 1, día_: 1, _s: 2, so: 2, ol: 2, le: 1, ea: 1, ad: 1, do: 1, o_: 1, _d: 1, de: 1, e_: 1, _u: 1, un: 1, n_: 2, _día: 1, _c: 1, co: 1, on: 1, l.: 1}
- Tomamos "_s": 2

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- Tomamos "_s": 2
- Vocabulario
  {m, e, d, i, o, í, a, _, s, l, u, n, c, ., dí, día, _s} con 17 entradas.
- Fragmentación
  {m, e, d, i, o, día, _s, o, l, e, a, d, o, _, d, e, _, u, n, _, día, _, c, o, n, _s, o, l, .} de 29 *tokens*.

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- **Paso 4**

  Frecuencia de pares

  {me: 1, ed: 1, di: 1, io: 1, odía: 1, día_s: 1, _so: 2, ol: 2, le: 1, ea: 1, ad: 1, do: 1, o_: 1, _d: 1, de: 1, e_: 1, _u: 1, un: 1, n_: 2, _día: 1, día_: 1, _c: 1, co: 1, on: 1, l.: 1}

- Tomamos "_so": 2

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- Tomamos "_so": 2
- Vocabulario
  {m, e, d, i, o, í, a, _, s, l, u, n, c, ., dí, día, _s, _so} con 18 entradas.
- Fragmentación
  {m, e, d, i, o, día, _so, l, e, a, d, o, _, d, e, _, u, n, _, día, _, c, o, n, _so, l, .} de 27 *tokens*.

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- **Paso 5**

  Frecuencia de pares

  {me: 1, ed: 1, di: 1, io: 1, odía: 1, día_so: 1, _sol: 2, le: 1, ea: 1, ad: 1, do: 1, o_: 1, _d: 1, de: 1, e_: 1, _u: 1, un: 1, n_: 2, _día: 1, día_: 1, _c: 1, co: 1, on: 1, l.: 1}.

- Tomamos "_sol": 2

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- Tomamos "_sol": 2
- Vocabulario
  {m, e, d, i, o, í, a, _, s, l, u, n, c, ., dí, día, _s, _so, _sol}
  con 19 entradas.
- Fragmentación
  {m, e, d, i, o, día, _sol, e, a, d, o, _, d, e, _, u, n, _, día, _, c, o, n, _sol, .} de 25 *tokens*.

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- **Paso 6**

  Frecuencia de pares

  {me: 1, ed: 1, di: 1, io: 1, odía: 1, día_sol: 1, _sole: 1,
  ea: 1, ad: 1, do: 1, o_: 1, _d: 1, de: 1, e_: 1, _u: 1,
  un: 1, n_: 1, _día: 1, día_: 1, _c: 1, co: 1,
  on: 1, n_sol: 1, _sol.: 1}

- Tomamos "me": 1

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- Tomamos "me": 1
- Vocabulario
  {m, e, d, i, o, í, a, _, s, l, u, n, c, ., dí, día, _s, _so, _sol, me} con 20 entradas.
- Fragmentación
  {me, d, i, o, día, _sol, e, a, d, o, _, d, e, _, u, n, _, día, _, c, o, n, _sol, .} de 24 *tokens*.

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- **Paso 7**

  Frecuencia de pares

  {med: 1, di: 1, io: 1, odía: 1, día_sol: 1, _sole: 1, ea: 1, ad: 1, do: 1, o_: 1, _d: 1, de: 1, e_: 1, _u: 1, un: 1, n_: 1, _día: 1, día_: 1, _c: 1, co: 1, on: 1, n_sol: 1, _sol.: 1}.

- Tomar "med": 1

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- Tomar "med": 1
- Vocabulario
  {m, e, d, i, o, í, a, _, s, l, u, n, c, ., dí, día, _s, _so, _sol, me, med} con 21 entradas.
- Fragmentación
  {med, i, o, día, _sol, e, a, d, o, _, d, e, _, u, n, _, día, _, c, o, n, _sol, .} de 23 *tokens*.

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- **Paso 8**

  Frecuencia de pares

  {medi: 1, io: 1, odía: 1, día_sol: 1, _sole: 1, ea: 1, ad: 1, do: 1, o_: 1, _d: 1, de: 1, e_: 1, _u: 1, un: 1, n_: 1, _día: 1, día_: 1, _c: 1, co: 1, on: 1, n_sol: 1, _sol.: 1}.

- Tomamos "medi": 1

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- Tomamos "medi": 1
- Vocabulario
  {m, e, d, i, o, í, a, _, s, l, u, n, c, ., dí, día, _s, _so, _sol, me, med, medi} con 22 entradas.
- Fragmentación
  {medi, o, día, _sol, e, a, d, o, _, d, e, _, u, n, _, día, _, c, o, n, _sol, .} de 22 *tokens*.

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- **Paso 9**
  Frecuencia de pares
  {medio: 1, odía: 1, día_sol: 1, _sole: 1, ea: 1, ad: 1, do: 1, o_: 1, _d: 1, de: 1, e_: 1, _u: 1, un: 1, n_: 1, _día: 1, día_: 1, _c: 1, co: 1, on: 1, n_sol: 1, _sol.: 1}.
- Tomamos "medio": 1

Fragmentación de texto

Ejemplo de aplicación de BPE

Corpus = "Mediodía soleado de un día con sol."

- Tomamos "medio": 1
- Vocabulario
  {m, e, d, i, o, í, a, _, s, l, u, n, c, ., dí, día, _s, _so, _sol, me, med, medi, medio} con 23 entradas.
- Fragmentación
  {medio, día, _sol, e, a, d, o, _, d, e, _, u, n, _, día, _, c, o, n, _sol, .} de 21 *tokens*.

Fragmentación de texto

Ejemplo de aplicación de BPE

- Si quisiéramos fragmentar la siguiente secuencia de texto :
  "En medio del lío solo medí el codo"
  usando el vocabulario obtenido tendríamos la siguiente fragmentación
  {e, n, _, medio, d, e, l, _, l, í, o, _sol, o, med, í, _, e, l, c, o, d, o, .}

Fragmentación de texto

Algoritmo BPE

- La principal motivación de los autores del método BPE fue la posibilidad de evitar la aparición de palabras en un texto que no pertenece al corpus con que fue entrenado el traductor.
- Este tipo de situaciones conlleva a la aparición de *tokens* $< UNK >$ o $< OOV >$ (acrónimo de su denominación en inglés *out of vocabulary*).
- Bajo esta perspectiva, lo relevante es incorporar al vocabulario fragmentos de palabras que permitieran formar palabras que no habían estado presentes en el corpus.

Fragmentación de texto

Algoritmo BPE

- Por otro lado, si lo que se pretende es acotar el tamaño de un vocabulario, se puede partir de uno que solo posea una cantidad suficiente de signos (letras y puntuación).
- A partir de éste vocabulario, expandirlo hasta un tamaño determinado controlado por la cantidad de adiciones de fragmentos (*merge* en la denominación en inglés por los autores del método).
- El algoritmo original de Sennrich, Haddow y Birch fue dado en Python.

Fragmentación de texto

Algoritmo BPE

```
import re, collections
def get_stats(vocab):
  pairs = collections.defaultdict(int)
  for word, freq in vocab.items():
    symbols = word.split()
    for i in range(len(symbols) - 1):
      pairs[symbols[i],symbols[i+1]] += freq
  return pairs

def merge_vocab(pair, v_in):
  v_out = {}
  bigram = re.escape(' '.join(pair))
  p = re.compile(r'(?<!\S)' + bigram + r'(?!\S)')
  for word in v_in:
    w_out = p.sub(''.join(pair), word)
    v_out[w_out] = v_in[word]
  return v_out

vocab = {'l o w </w>' : 5, 'l o w e r </w>' : 2,
'n e w e s t </w>':6, 'w i d e s t </w>':3}
num_merges = 10
for i in range(num_merges):
  pairs = get_stats(vocab)
  best = max(pairs, key=pairs.get)
  vocab = merge_vocab(best, vocab)
  print(best)
```

Fragmentación de texto

Otros métodos

- Hay otros métodos de fragmentación tales como *WordPiece* y *unigram*.
- Cada uno tiene sus ventajas y limitaciones bajo determinados escenarios.

Fragmentación de texto

Otros métodos

- BPE y *WordPiece* parten de un vocabulario acotado y agregan entradas.
- *unigram* parte de un vocabulario grande y remueve entradas.
- *unigram* trabaja con una función de pérdida (*loss*) calculada sobre todo el corpus. Las entradas en el vocabulario se irán removiendo si esto permite disminuir el valor de la función de pérdida más que removiendo otras entradas. La idea es remover lo que más hace caer la pérdida.

Fragmentación de texto

Otros métodos

- *WordPiece* fue desarrollado por Google para pre-entrenar a BERT. Si bien, Google no abrió el código de *WordPiece* se pudo establecer provisoriamente que funciona de la siguiente manera.
- Parte de un vocabulario formado por las letras del texto aunque, las letras que son continuación de la letra inicial en una palabra las incluye en el vocabulario antecediéndolas con "##".
- De esa forma, a partir de "casa", genera las siguientes entradas {c, ##a, ##s, ##a}.

Fragmentación de texto

Otros métodos

- Luego, elige el par que maximiza la frecuencia del par dividido por el producto de las frecuencias de las componentes del par.
  De esta forma, si un par está formado por componentes muy frecuentes tendrá menos chance de ser elegido como entrada en el vocabulario.

Fragmentación de texto

Usando librerías

- En general, las librerías asociadas a un modelo (por ejemplo, *Transformers*) incluyen su propia implementación de los métodos de fragmentación.
- También se puede usar una librería independiente que tiene implementado los métodos de fragmentación y ese es el caso de *tokenizers*.
- Aquí se puede observar un ejemplo de uso de dicha librería en Python.

Fragmentación de texto

Usando librerías

```
from tokenizers import Tokenizer, models, trainers, pre_tokenizers

# Inicializar el fragmentador con el método BPE
tokenizer = Tokenizer(models.BPE())
# Indicar que separe el texto en palabras. Si se omite, lo separará en caracteres
tokenizer.pre_tokenizer = pre_tokenizers.Whitespace()

# Crear un fragmentador BPE indicando de cuánto se desea sea el
# tamaño del vocabulario y cuál es la minima frecuencia para
# incluir un par en el vocabulario
trainer = trainers.BpeTrainer(vocab_size = 190, min_frequency = 2)
# Indicar cual es el corpus sobre el cual trabajará BPE
tokenizer.train(["mi_corpus.txt"], trainer = trainer)

print("Tam vocabulario: ",tokenizer.get_vocab_size())
print("Vocabulario: ",tokenizer.get_vocab())

# Dado un ejemplo, separarlo en tokens de acuerdo al vocabulario
# obtenido
ejemplo = "La principal motivación de los autores del método BPE"
ejemplo_fragmentado = tokenizer.encode(ejemplo)
print(ejemplo)
print(ejemplo_fragmentado.tokens)
```

Fragmentación de texto

Referencias

- Sennrich, R., Haddow, B., y Birch, A. (2015). Neural machine translation of rare words with subword units. arXiv preprint arXiv:1508.07909
- Kudo, T. (2018). Subword regularization: Improving neural network translation models with multiple subword candidates. arXiv preprint arXiv:1804.10959.
- https://huggingface.co/learn/llm-course/es/chapter6/4 (*LLM course of Higging Face*)