Aprendizaje automático avanzado
Transformadores

Juan Miguel Santos

Laboratorio de investigación y desarrollo experimental en computación (LIDEC)
Universidad Nacional de Hurlingham

(24 de septiembre de 2026)

Implementación de métodos de cálculo

Introducción

Hay dos hechos fácilmente constatables que son:

- un adulto posee un vasto vocabulario, y
- un niño, desde su nacimiento, va adquiriendo la capacidad de hablar y comprender lo que otros hablan y parte de ese proceso es **incorporar nuevas palabras al vocabulario**.

Por lo tanto, podemos establecer un incremento promedio de la cantidad de palabras incorporadas por día.

Implementación de métodos de cálculo

Introducción

- Supongamos que un joven de, por ejemplo **20 años**, conoce unas **10.000 palabras**.
- Si la incorporación de palabras a su vocabulario fuera uniforme, incorporará unas **500 palabras por año**, o sea, algo más de una palabra por día.
- La idea de aprender palabras en forma acumulativa convive con otra idea que es la **hipótesis distribucional**.

Implementación de métodos de cálculo

Introducción

- Esta hipótesis plantea que en la adquisición del lenguaje no sólo se aprenden palabras o frases por separado con sus significado por exposición durante la lectura o por una conversación.
- Hay otro mecanismo que permite aprender el significado por co-ocurrencia con otras palabras de las cuales sí se conoce el significado.
- Ese mecanismo puede ser aprendido o, innato y desarrollado.

Implementación de métodos de cálculo

Introducción

- Es decir, hay un proceso del conocimiento del lenguaje que es más abarcativo que aprender (conocer su significado) palabras o frases por separado.
- A dicho proceso lo podemos asimilar al concepto de **aprender un modelo del lenguaje**.

Transformador

Introducción

- En el contexto de este curso lo nombraremos como **pre-entrenamiento**.

Transformador

Introducción

- El modelo aprendido durante este proceso se denomina **modelo de lenguaje**.
- El término **modelos de grandes lenguajes** (MGL) o *Large Language Models* (LLM) en inglés refiere excatamente al mismo concepto pero también alude en la forma que se creó el modelo.

Transformador

Introducción

- En los MGL el modelo se construye a partir de una gran cantidad de datos (por ejemplo, corpus formados a partir de millones de documentos).
- Para esto es requerido un gran poder de cálculo y de almacenamiento debido a la gran cantidad de parámetros libres (i.e. pesos sinápticos).

Transformador

Introducción

- El estado del arte actual indica a los **Transformadores** (o Transformers en inglés) como el método adecuado para aprender un MGL.

Transformador

Introducción

- Los tranformadores usan de un mecanismo llamado auto-atención (AA) o *self-attention* en inglés.
- El uso de AA fue introducido previamente en el desarrollo de las redes neuronales recurrentes también para la obtención de MGL.
- El mecanismo de AA permite dar una representación de una palabra basado en el contexto en que se halla.

Transformador

Introducción

- Un MGL es un dispositivo formal que permite predecir las palabras siguientes en un texto dada la secuencia inmediata anterior.
- Casi cualquier tarea de PLN puede ser alcanzada mediante la predicción de una palabra (siguiente o inserta en un contexto).

Transformador

Auto-atención

- Cuando un Transformador es usado para modelar un predictor de lenguaje (*causal language modelling*) la entrada del transformador es una secuencia de palabras y la salida es la predicción de la próxima palabra.
- Los transformadores son construidos por una secuencia (apilamiento) de bloques de transformación.

Transformador

Auto-atención

- La idea del bloque es obtener una representación v'_{p_i} para cada palabra p_i en la entrada teniendo en cuenta una representación propia v_{p_i} pero también la representación v_{p_j} de las otras palabras $p_j, j \neq i$ en la entrada.

Transformador

Auto-atención

- Esto quiere decir que una palabra no tendrá siempre la misma representación (representación contextual) sino que dependerá de la posición que tenga en la entrada y de qué palabras esté rodeada.

Transformador

Auto-atención

- Estos bloques están formados por:
  - capas lineales,
  - capas de **auto-atención**, y
  - capas completamente conectadas.

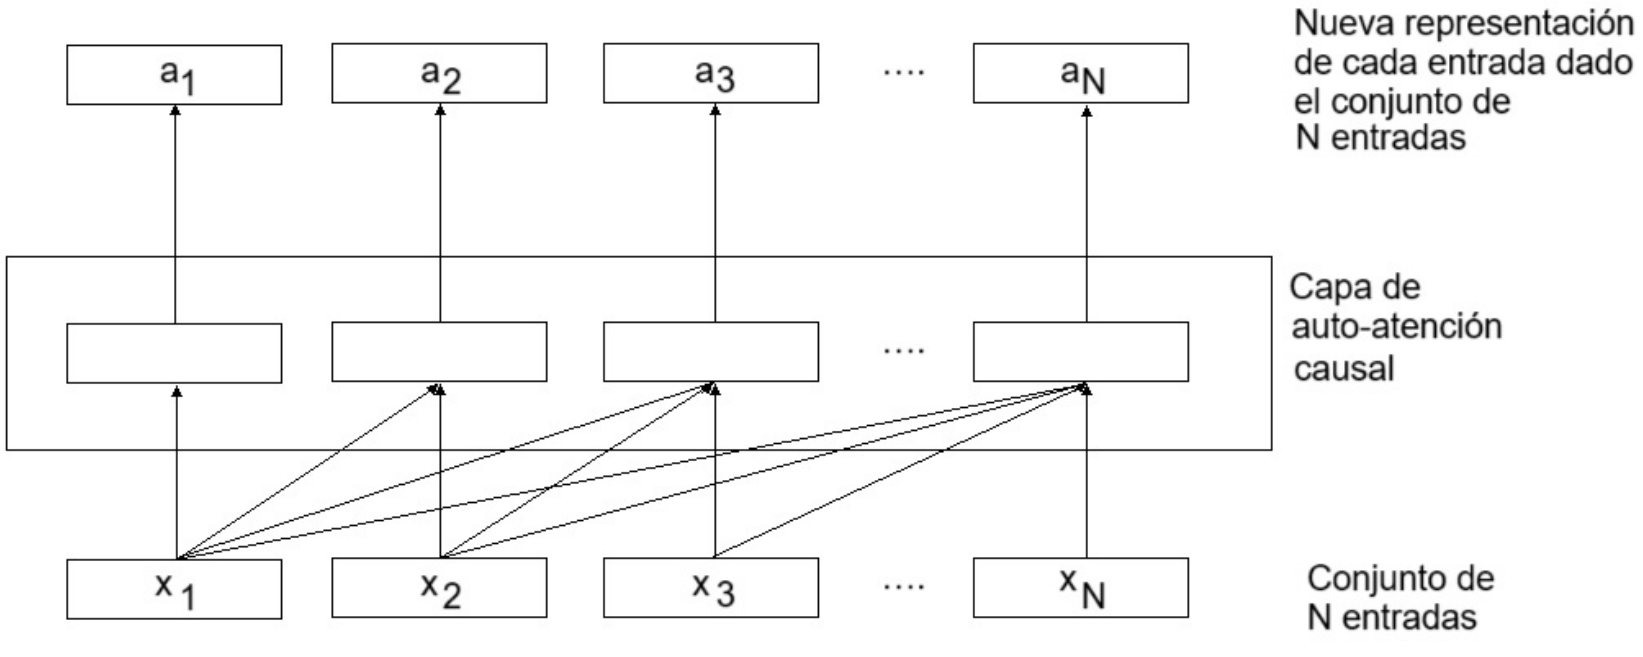
Transformador

Auto-atención

- Hay dos tipos de auto-atención:
  - causal,
  - bi-direccional.
- En la causal, la representación de una palabra es modificada basada en la representación de las palabras precedentes.
- En la bidireccional, la representación de una palabra es modificada basada en la representación de las palabras que están tanto antes como después.

Transformador

Auto-atención



Transformador

Auto-atención

Dos observaciones acerca de la auto-atención causal.

1. Puede ser usado para auto-regresión, es decir, poder predecir la representación de una palabra basado en la representación de las previas.
2. Puede **calcular en paralelo** cada nueva representación de cada palabra de la entrada teniendo en cuenta las palabras previas en cada caso.

Transformador

Auto-atención

- Sea una secuencia de entrada $(x_1, x_2, ..., x_N)$ y la secuencia de salida $(a_1, a_2, ..., a_N)$.
- Para obtener la representación de a_3 nos vamos a valer de la representación de x_1, x_2 y x_3.
- ¿De qué manera?
- Viendo qué grado de similitud que tiene x_3 con x_1, x_3 con x_2 y x_3 con x_3 usando el **producto interno**.

Transformador

Auto-atención

- Como el valor que da el producto interno no puede ser evaluado en un rango estándar para un conjunto arbitrario de representaciones de palabras, le aplicamos softmax para obtener valores entre 0 y 1.
- Definimos así, inicialmente, a $\alpha_{i,j}$ como
$$\alpha_{i,j} = \mathit{softmax}(\mathit{similitud}(x_i, x_j)) \text{ para todo } j \leq i.$$
- La representación de a_i la definimos como

$$a_i = \sum_{j \leq i} \alpha_{i,j} x_j.$$

Transformador

Auto-atención

- Veamos una forma alternativa y más precisa de definir similitud.
- En el mecanismo de auto-atención la representación de cada palabra puede adoptar 3 roles:
  - **consulta** (*query* en inglés),
  - **clave** (*key* en inglés), y
  - **valor** (*value* en inglés).

Transformador

Auto-atención

- En el **rol de consulta**, la representación es transformada para poder ser comparada con otras palabras en la entrada.
- En el **rol de clave**, la representación es transformada para poder ser comparada con la palabra en foco.

Transformador

Auto-atención

- En el **rol de valor**, la representación es transformada para poder calcular el valor final de la representación de cada palabra basados en:
  - en la propia representación de valor,
  - la representación de clave de las palabras precedentes y
  - la representación de consulta de la palabra en foco.

Transformador

Auto-atención

- Para obtener la representación en cada uno de los 3 roles, cada *token* (representación contextual) es multiplicada por 3 matrices:

$$W^Q \in R^{d \times d_k}.$$

$$W^K \in R^{d \times d_k}$$

y

$$W^V \in R^{d \times d_v}.$$

Transformador

Auto-atención

- Así, las representaciones de las palabras según sus roles son

$$q_i = x_i W^Q$$
$$k_i = x_i W^K, \text{ y}$$
$$v_i = x_i W^V$$

donde $x_i \in R^{1\times d}$,
los vectores $q_i, k_i \in R^{1\times d_k}$,
el vector $v_i \in R^{1\times d_v}$, y d es la dimensión del vector de representación contextual de cada token.

Transformador

Auto-atención

- En el artículo original de transformadores (Vaswani et al., 2017), $d = 512$ y $d_k = d_v = 64$.
- Para tener una idea acerca del valor 512, recordemos que Mikolov, en los métodos word2vec, propone usar el valor 300.

Transformador

Auto-atención

- Basado en los roles, redefinimos la similitud entre x_i y x_j como:

$$similitud(x_i, x_j) = q_i k_j.$$

- La similitud ya no es el producto interno entre x_i y x_j sino entre q_i y k_j.
- Así, el cálculo de $\alpha_{i,j}$ se convierte en

$$\alpha_{i,j} = softmax(q_i k_j).$$

Nota: fijarse que el producto $q_i k_j$ se refiere al producto interno entre vectores.

Si quisiéramos escribirlo como producto de matrices debiéramos transponer alguno de los dos vectores, por ejemplo $q_i k_j^t$.

Transformador

Auto-atención

- Por lo tanto, podemos obtener a_i como
$$a_i = \sum_{j \leq i} \alpha_{i,j} v_j = \\ = \sum_{j \leq i} softmax(q_i k_j) v_j.$$
- Como el producto $q_i k_j$ puede tomar valores muy grandes que afecten numéricamente el método de aprendizaje se escala dicho producto dividiéndolo por la raíz de d_k.

Transformador

Auto-atención

- Así $similitud(x_i, x_j)$ resulta en

$$similitud(x_i, x_j) = \frac{q_i k_j}{\sqrt{d_k}}.$$

- Finalmente a_i se obtiene según

$$a_i = \sum_{j \leq i} \alpha_{i,j} v_j =$$

$$a_i = \sum_{j \leq i} softmax(\frac{q_i k_j}{\sqrt{d_k}}) v_j.$$

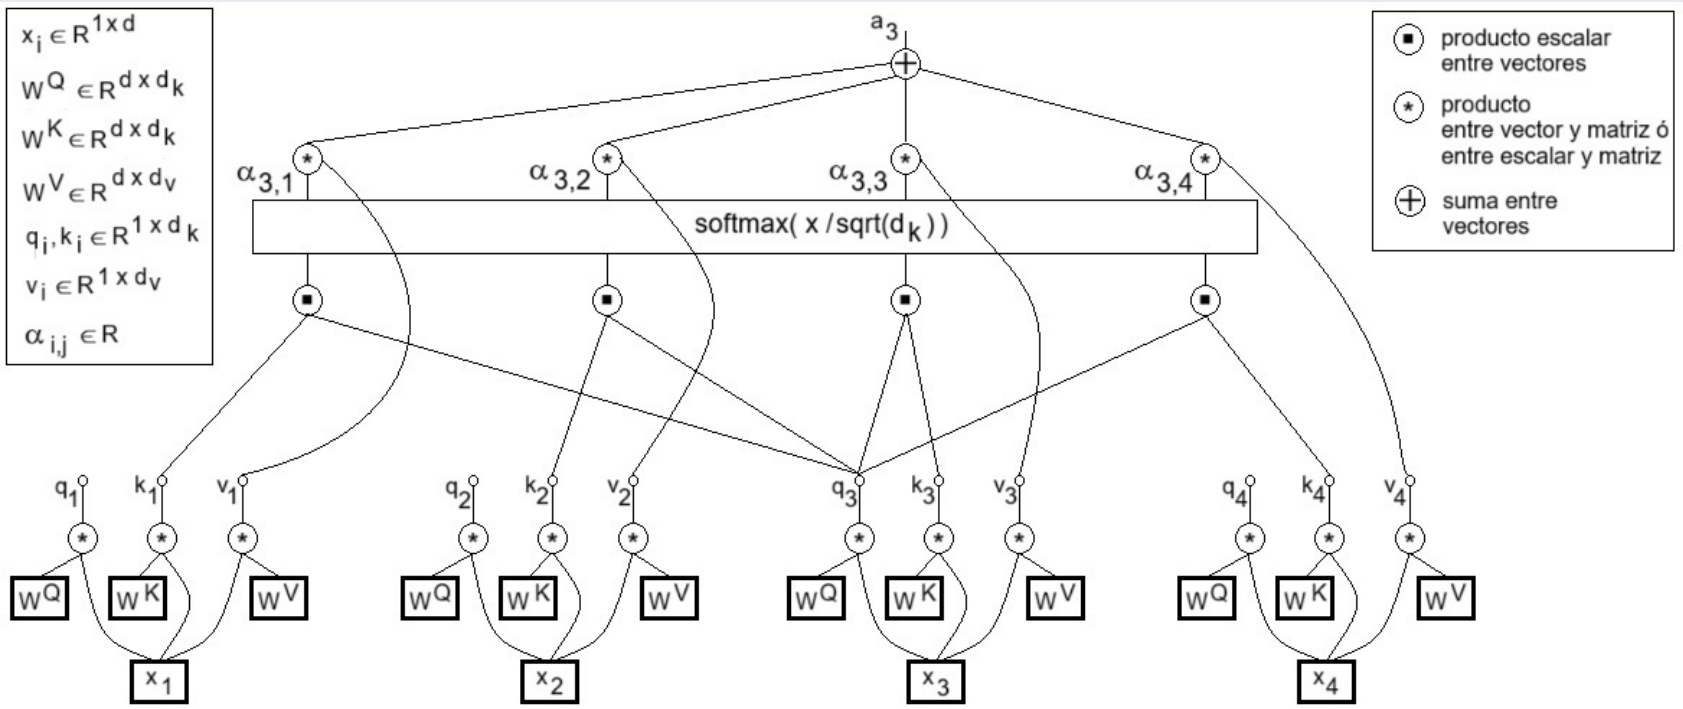
Transformador

Auto-atención

- Es importante interpretar adecuadamente la forma de expresar el cálculo de $\alpha_{i,j}$.
- $\alpha_{i,j} = softmax(q_i k_j)$ está expresando la componente j de la función *softmax* ya que $softmax(q_i k_j)$ depende de k_j pero también del resto de las $k_{j'}, 1 \leq j' \leq j$.
- En rigor, $\alpha_{i,j}$ la debiéramos expresar como
$$\alpha_{i,j} = softmax_j(q_i, k_j, k_1, k_2, ..., k_{j-1}), j > 1$$
pero, por comodidad, usaremos la notación como hasta ahora.

Transformador

Auto-atención



Transformador

Auto-atención. Notación matricial.

- Vamos a notar los N vectores de entrada en una matriz $X \in R^{N \times d}$ donde cada fila de la matriz X tiene la representación contextual de cada una de los N tokens en la entrada (N puede ser 1024, 2048 o 4096, o algún otro valor).
- Si multiplicamos X por W^Q, W^K y W^V tenemos

$$Q = XW^Q$$
$$K = XW^K, \text{ y}$$
$$V = XW^V$$

donde $Q, K \in R^{N \times d_k}$ y $V \in R^{N \times d_v}$.

Transformador

Auto-atención. Notación matricial.

- Así, multiplicando Q por K^t podemos obtener todos los productos entre los q_i y los k_j,
- Nota: pensar que cada fila de Q es un q_i y cada columna de K^t es un k_j, así que el elemento (i, j) de la matriz QK^t tiene el producto $q_i k_j$.
- $QK^t \in R^{N \times N}$.

Transformador

Auto-atención. Notación matricial.

- Finalmente, tenemos la expresión matricial de los y_i (que hasta ahora estábamos notando como a_i) como

  $$Y = autoAtencion(X, W^Q, W^K, W^V)$$
  $$Y = autoAtencion(Q, K, V)$$

  $$Y = softmax(\frac{QK^t}{\sqrt{d_k}})V$$

  donde $Y \in R^{N \times d_v}$.

- Atención: el cálculo de la función softmax se hace sobre cada fila de la matriz $QK^t/\sqrt{d_k}$.

Transformador

Auto-atención. Notación matricial.

- Como se ha mencionado, cada elemento (i, j) de la matriz QK^t contiene la similitud entre x_i y x_j ya que cada uno de ellos se calcula como $q_i k_j$.
- Sin embargo, si el mecanismo de auto-atención es **causal**, no tiene sentido incluir en el softmax de cada fila las similitudes entre q_i y k_j para j mayores a i.

Transformador

Auto-atención. Notación matricial.

- Para evitar eso, se sobre escribe cada elemento $(i, j), j > i$ de la matriz QK^t un valor -**infinito**.
- De este modo, al calcular el *softmax* para cada fila i, los valores de $softmax(\frac{QK^t}{\sqrt{d_k}})$ queden en 0 para los $q_i k_j$ con $j > i$.

Transformador

Auto-atención. Notación matricial.

$q_1 k_1$	-inf	-inf	-inf	-inf	-inf
$q_2 k_1$	$q_2 k_2$	-inf	-inf	-inf	-inf
$q_3 k_1$	$q_3 k_2$	$q_3 k_3$	-inf	-inf	-inf
...	...	...	...	-inf	-inf
$q_{N-1} k_1$	$q_{N-1} k_2$	...	...	$q_{N-1} k_{N-1}$	-inf
$q_N k_1$	$q_N k_2$	$q_N k_3$	...	$q_N k_{N-1}$	$q_N k_N$

$Q\,W^t$ con enmascaramiento. Cada fila *i* corresponde a la similitud del token *i* con el resto de los tokens *j*, con *j* menor o igual a *i*. La función *softmax* se calcula por fila.

Transformador

Auto-atención. Notación matricial.

- Antes de ver la notación matricial habíamos establecido que

$$a_i = \sum_{j \leq i} \alpha_{i,j} v_j$$

$$a_i = \sum_{j \leq i} softmax(\frac{q_i k_j}{\sqrt{d_k}}) v_j.$$

donde es evidente que la nueva representación contextual a_i de x_i es la combinación lineal de los v_j dada por los $\alpha_{i,j}$.

Transformador

Auto-atención. Notación matricial.

- La notación matricial
$$Y = softmax(\frac{QK^t}{\sqrt{d_k}})V$$
puede resultar poco intuitiva en el sentido que no es evidente cómo cada fila y_i de Y es la combinación lineal que nos referimos en la diapositiva anterior.
(Nota: aquí nombramos indistintamente y_i o a_i a dicha combinación lineal.)
- Partiremos entonces desarmando la combinación lineal a_i para luego encontrar que es lo mismo que la y_i que se obtiene mediante la notación matricial.

Transformador

Auto-atención. Notación matricial.

- La ecuación

$$a_i = \sum_{j \leq i} \alpha_{i,j} v_j$$

la podemos expresar como

$$\begin{aligned} a_i = \alpha_{i,1} v_1 + \alpha_{i,2} v_2 + \ldots + \alpha_{i,N} v_N \\ a_i = (\alpha_{i,1} v_{1,1} + \alpha_{i,2} v_{2,1} + \ldots + \alpha_{i,N} v_{N,1}, \\ \alpha_{i,1} v_{1,2} + \alpha_{i,2} v_{2,2} + \ldots + \alpha_{i,N} v_{N,2}, \\ \ldots, \\ \alpha_{i,1} v_{1,v_d} + \alpha_{i,2} v_{2,v_d} + \ldots + \alpha_{i,N} v_{N,v_d}) \end{aligned}$$

donde cada componente k de a_i es la suma de los productos de los $\alpha_{i,j}$ por la componente k de cada v_j, $1 \leq k \leq v_d$, $1 \leq j \leq N$.

Transformador

Auto-atención. Notación matricial.

- Ahora volvamos a la ecuación matricial

$$Y = softmax(\frac{QK^t}{\sqrt{d_k}})V$$

y la escribimos así

$$Y = \begin{pmatrix} \alpha_{1,1} & \alpha_{1,2} & \dots & \alpha_{1,N} \\ \alpha_{2,1} & \alpha_{2,2} & \dots & \alpha_{2,N} \\ \dots & & & \\ \alpha_{N,1} & \alpha_{N,2} & \dots & \alpha_{N,N} \end{pmatrix} \begin{pmatrix} v_{1,1} & v_{1,2} & \dots & v_{1,v_d} \\ v_{2,1} & v_{2,2} & \dots & v_{2,v_d} \\ \dots & & & \\ v_{N,1} & v_{N,2} & \dots & v_{N,v_d} \end{pmatrix}$$

donde Y es

$$\begin{pmatrix} y_{1,1} & y_{1,2} & \dots & y_{1,v_d} \\ y_{2,1} & y_{2,2} & \dots & y_{2,v_d} \\ \dots & & & \\ y_{N,1} & y_{N,2} & \dots & y_{N,v_d} \end{pmatrix}.$$

Transformador

Auto-atención. Notación matricial.

- Para obtener el elemento $(i, 1)$ de la matriz Y, es decir $y_{i,1}$, debemos multiplicar la fila i de los coeficientes $\alpha_{i,j}$ por la columna 1 de la matriz V, esto es

$$y_{i,1} = \alpha_{i,1} v_{1,1} + \alpha_{i,2} v_{2,1} + ... + \alpha_{i,N} v_{N,1}.$$

- Para el elemento $y_{i,2}$ de y_i debemos multiplicar la fila i de los coeficientes $\alpha_{i,j}$ por la columna 2 de la matriz V, esto es

$$y_{i,2} = \alpha_{i,1} v_{1,2} + \alpha_{i,2} v_{2,2} + ... + \alpha_{i,N} v_{N,2}.$$

Transformador

Auto-atención. Notación matricial.

- Para obtener el elemento (i, d_v) de la matriz Y es decir y_{i,d_v}, debemos multiplicar la fila i de los coeficientes $\alpha_{i,j}$ por la columna d_v de la matriz V, esto es

$$y_{i,d_v} = \alpha_{i,1} v_{1,d_v} + \alpha_{i,2} v_{2,d_v} + \ldots + \alpha_{i,N} v_{N,d_v}.$$

Transformador

Auto-atención. Notación matricial.

- Si comparamos el primer elemento de a_i de la diapositiva 40 con $y_{i,1}$ veremos que son iguales.
- Lo mismo cuenta para los demás elementos de a_i de la diapositiva 40 cuando los comparamos con los elementos de y_i.

Transformador

Auto-atención. Atención múltiple.

- El método de auto atención captura las relaciones de cada palabra con el resto de las palabras en la entrada.
- Eso dependerá de las transformaciones realizadas por W^Q, W^K y W^V, es decir cómo se formen las consultas, las claves y los valores.

Transformador

Auto-atención. Atención múltiple.

- ¿Qué pasaría si usáramos valores diferentes para estas matrices?
- Claramente, la representación obtenida que indica las relaciones de las palabras entre sí, cambiaría.

Transformador

Auto-atención. Atención múltiple.

- Sin embargo, no queda claro en qué sentido cambiaría.
- Podemos pensar que diferentes grupos de matrices W^Q, W^K y W^V van a capturar relaciones que quizás se deban a diferentes aspectos del lenguajes.
- Por ejemplo, podrían capturar aspectos sintácticos, aspectos semánticos, aspectos de causalidad o aspectos de metáfora, etc.

Transformador

Auto-atención. Atención múltiple.

- De modo que, en vez de usar solo un juego de matrices W^Q, W^K y W^V, usaremos h juegos de matrices y por lo tanto obtendremos $N \times d_v$ por h salidas.
- Ahora, nuestra salida dejará de ser N vectores de dimensión d_v sino que concatenaremos los N vectores obtenidos con cada juego de matrices W^Q, W^K y W^V.
- Así, la matriz de salida tendrá dimensión $N \times hd_v$.

Transformador

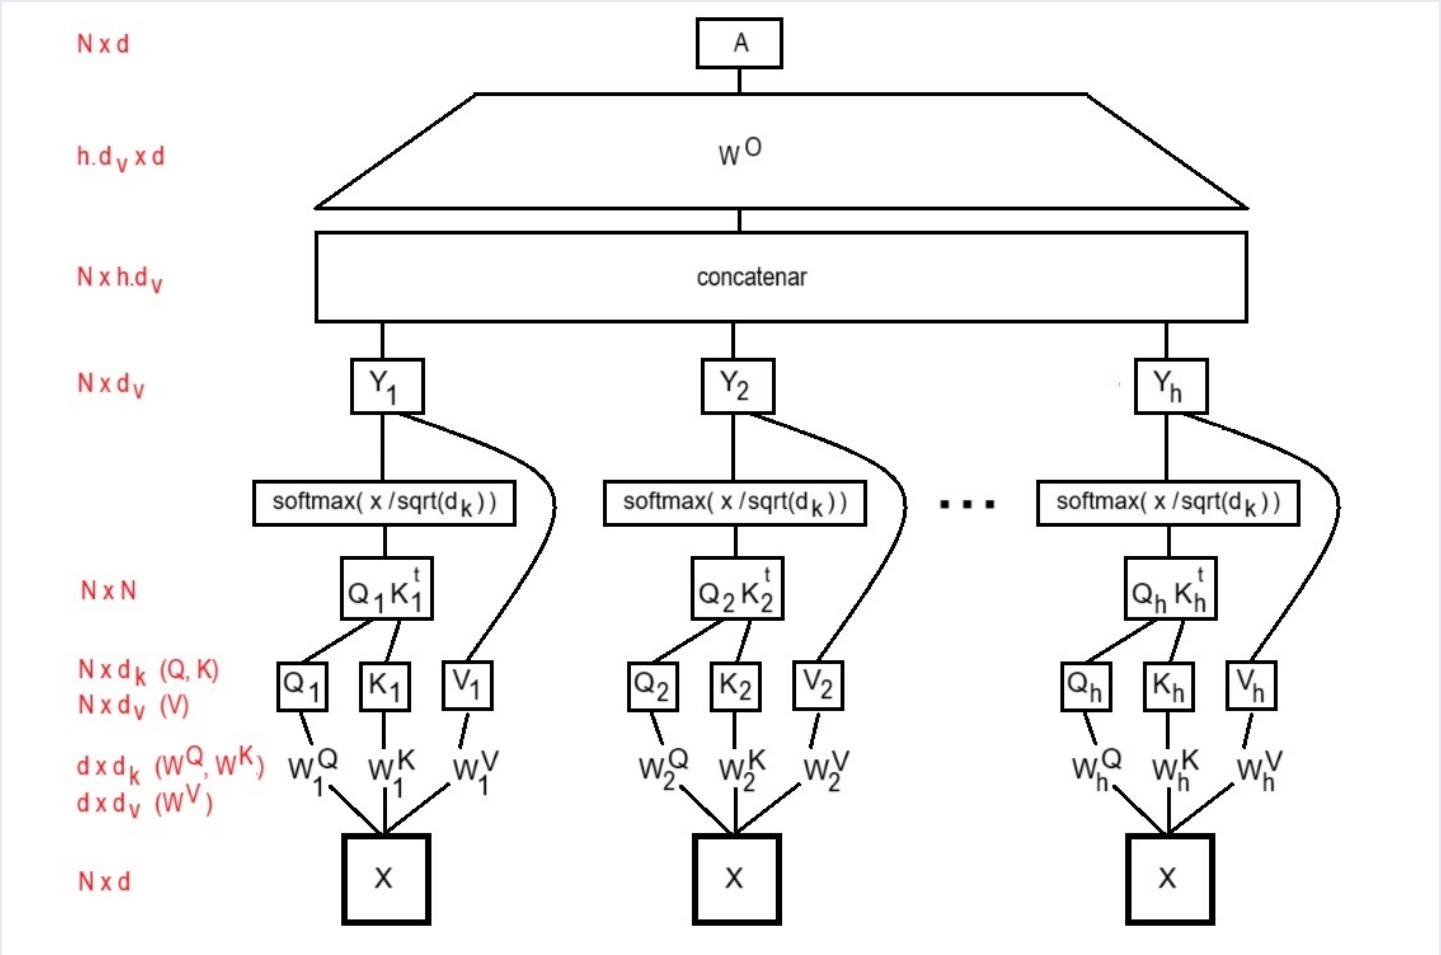
Auto-atención. Atención múltiple.

Nota:

- Como cada Y_i es un vector con d_v elementos, se concatenará todos los Y_i obteniéndose un vector de dimensión $h.d_v$.
- A este vector obtenido se le aplicará una transformación $W^O \in R^{h.dv \times d}$ que dejará la salida A de dimensión $N \times d$.

Transformador

Auto-atención. Atención múltiple.



Transformador

Auto-atención. Atención múltiple.

- Sea k talque $1 \leq k \leq h$, obtendremos matrices Q_k, K_k y V_k para cada k:

$$Q_k = XW_k^Q$$
$$K_k = XW_k^K$$
$$V_k = XW_k^V.$$

- Entonces

$$Y_k = softmax(\frac{Q_k K_k^t}{\sqrt{d_k}})V_k$$

y

$$A = (Y_1 +' Y_2 +' ... +' Y_h)W^O$$

donde $+'$ indica concatenación de vectores de dimensión d_v.