Aprendizaje automático avanzado
Transformadores

Juan Miguel Santos

Laboratorio de investigación y desarrollo experimental en computación (LIDEC)
Universidad Nacional de Hurlingham

(1 de octubre de 2026)

Transformador

Bloque de transformación

- La estructura del mecanismo de auto-atención es la parte más importante del bloque de transformación.
- Sin embargo, la estructura completa requiere adicionalmente de
  - una capa de N PMCs,
  - dos capas de normalización, y
  - conexiones residuales.

Transformador

Bloque de transformación

- La **capa de N PMCs** tiene exactamente eso: cada perceptrón multicapa conectará d elementos de la salida de la capa de auto-atención con d elementos de la capa de salida del bloque de transformación mediante una capa oculta.
- En el artículo donde fue introducido este modelo de Transformador, si el tamaño de la representación contextual (d) es 512, el tamaño de la capa oculta es 2048 y es notado como d_{ff}.

Transformador

Bloque de transformación. Nota.

Nota:

- Cada *PMC* opera sobre cada *token* individualmente.
- Supongamos un lote de tamaño 10, donde cada ejemplo del lote tiene N *tokens* (palabras).
- El lote es un tensor de $10 \times N \times d$.
- Como la salida de cada *PMC* tiene dimensión d y hay N *PMC*s, la salida para cada ejemplo (de $N \times d$) será de $N \times d$.

Transformador

Bloque de transformación. Nota.

Nota:

- La salida de la capa de los *PMC*s será un tensor de $10 \times N \times d$.
- Los pesos de los *PMC* serán compartidos entre los *tokens*. Es decir, cada *PMC* que procesa un *token* tiene los mismos pesos que los *PMC*s que procesan los otros *tokens*. De hecho, esta operación se hace en paralelo.

Transformador

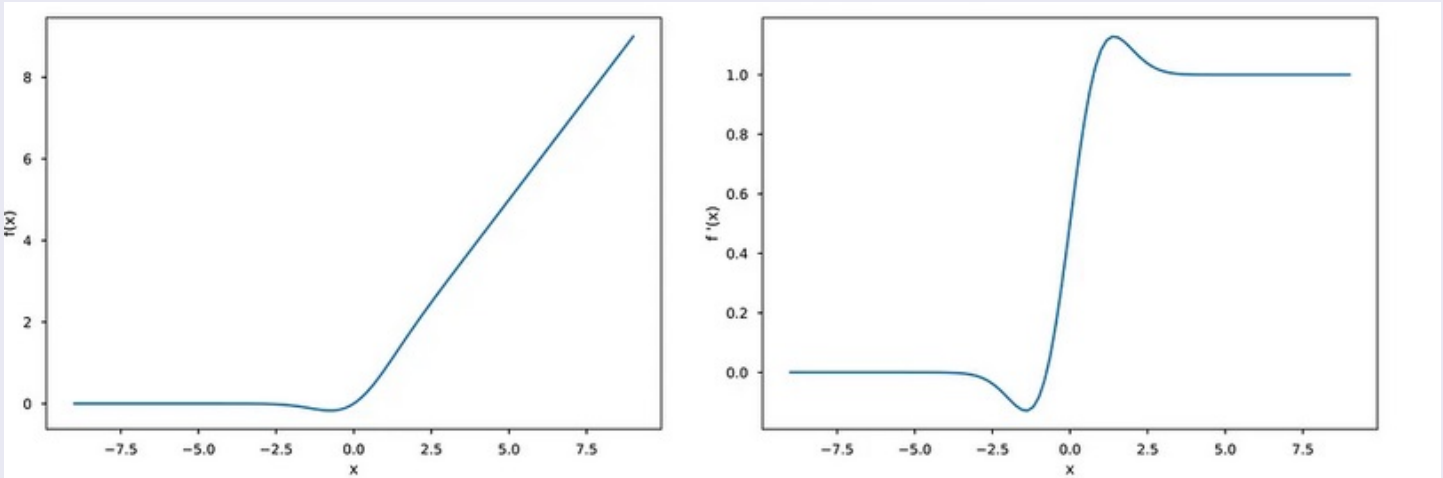
Bloque de transformación. Nota.

Nota:

- La capa oculta de los *PMC*s de la capa *PMC* tiene unidades con función de activación *GELU* (*Gaussian Error Linear Unit*).
- La función $GELU(x)$ está definida según:
  $GELU(x) = 0,5x(1 + tanh(\sqrt{\frac{2}{\pi}}(x + 0,044715x^3)))$
  aunque, en la **práctica**, se usa la siguiente definición:
  $GELU(x) = 0,5x(1 + tanh(\frac{x}{\sqrt{2}}))$.

Transformador

Bloque de transformación. Nota.



Funciones GELU(x) y GELU'(x)

(Extraida de https://medium.com/@abhishekjainindore24/silu-and-gelu-activation-function-in-tra-a808c73c18da)

Transformador

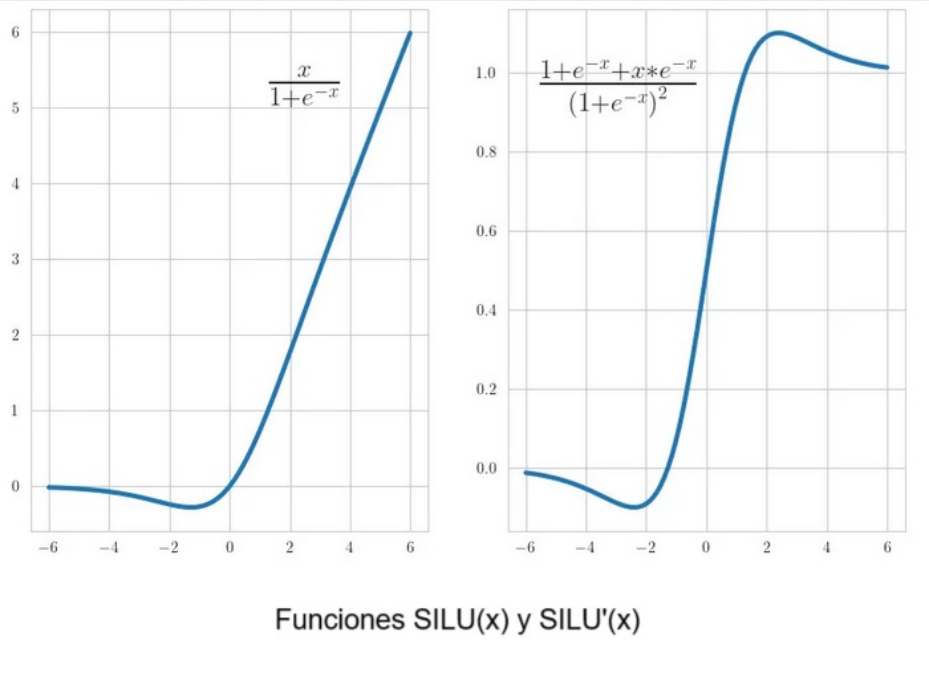
Bloque de transformación. Nota.

Nota:

- La función SILU (*Sigmoid Linear Unit*) está definida según:
$$SILU(x) = x\sigma(x)$$
donde $\sigma(x) = \frac{1}{1+\exp^{-x}}$ que es una función sigmoidea denominada función logística.
- Tiene las siguientes características:
  - Es una función suave y no monótona.
  - El comportamiento de su derivada mostró, experimentalmente, mejores resultados que la RELU.
  - Para x negativo la salida de la función no es 0.

Transformador

Bloque de transformación. Nota.



Funciones SILU(x) y SILU'(x)

(Extraida de https://medium.com/@abhishekjainindore24/silu-and-gelu-activation-function-in-tra-a808c73c18da)

Transformador

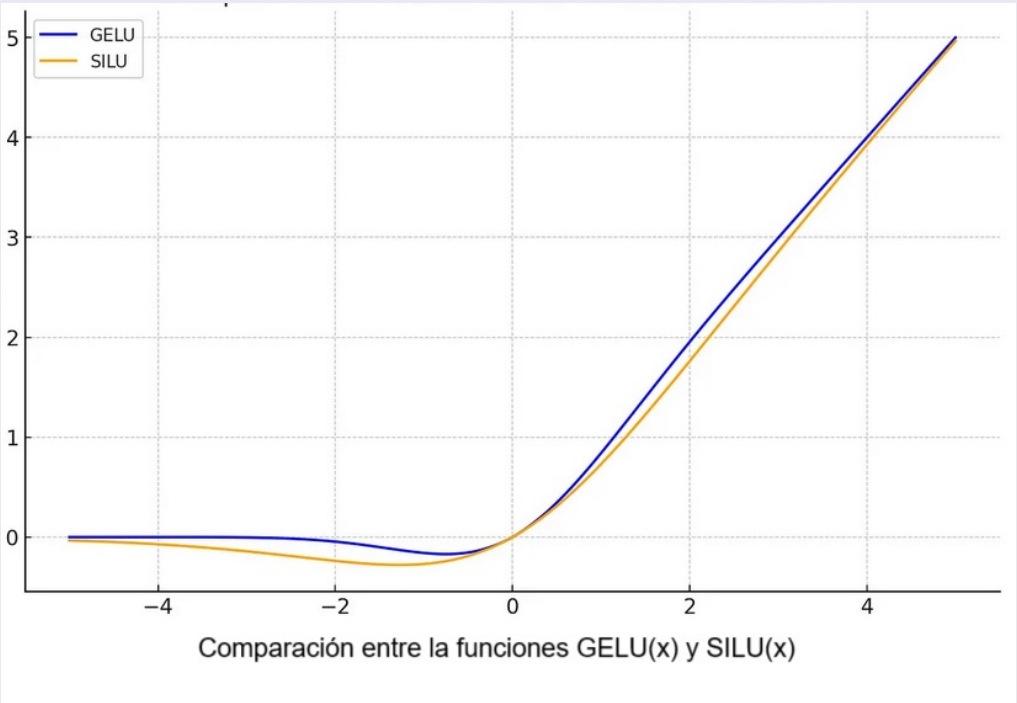
Bloque de transformación. Nota.

Nota:

- Función *SILU* es computacionalmente menos compleja que la función *GELU*.
- Si bien son parecidas, experimentalmente (sobre todo con Transformadores) se encontró más eficaz la *GELU* que la *SILU*.

Transformador

Bloque de transformación. Nota.



Comparación entre la funciones GELU(x) y SILU(x)

(Extraida de https://medium.com/@abhishekjainindore24/silu-and-gelu-activation-function-in-tra-a808c73c18da)

Transformador

Bloque de transformación

- La **conexiones residuales** son conexiones directas de la entrada con la salida adicionándose a esta última.
- Hay conexiones residuales entre la entrada X y la salida de la capa de auto-atención A y, entre la entrada de la capa de los N PMCs A y la salida de la misma.

Transformador

Bloque de transformación

- La **capa de normalización** es un mecanismo para mantener los valores de los elementos de los vectores de representación (de dimensión d) acotados.
- Simplemente se calcula la media y la desviación de los valores que componen el vector y luego se le resta a cada elemento la media y se lo divide por la desviación.
- Finalmente, a los valores obtenidos se le aplica una transformación $\gamma x + \beta$ donde γ y β son aprendidos ¿Cómo?

Transformador

Bloque de transformación

- Poniendo todo junto nos queda:

$$O = Normalizacion(X + autoAtencion(X))$$
$$H = Normalizacion(O + PMC(O))$$

donde

$X + autoAtencion(X)$ expresa la conexión residual de X sobre la salida de $autoAtencion(X)$ y

$O + PMC(O)$ expresa la conexión residual de O sobre la salida de $PMC(O)$.

Transformador

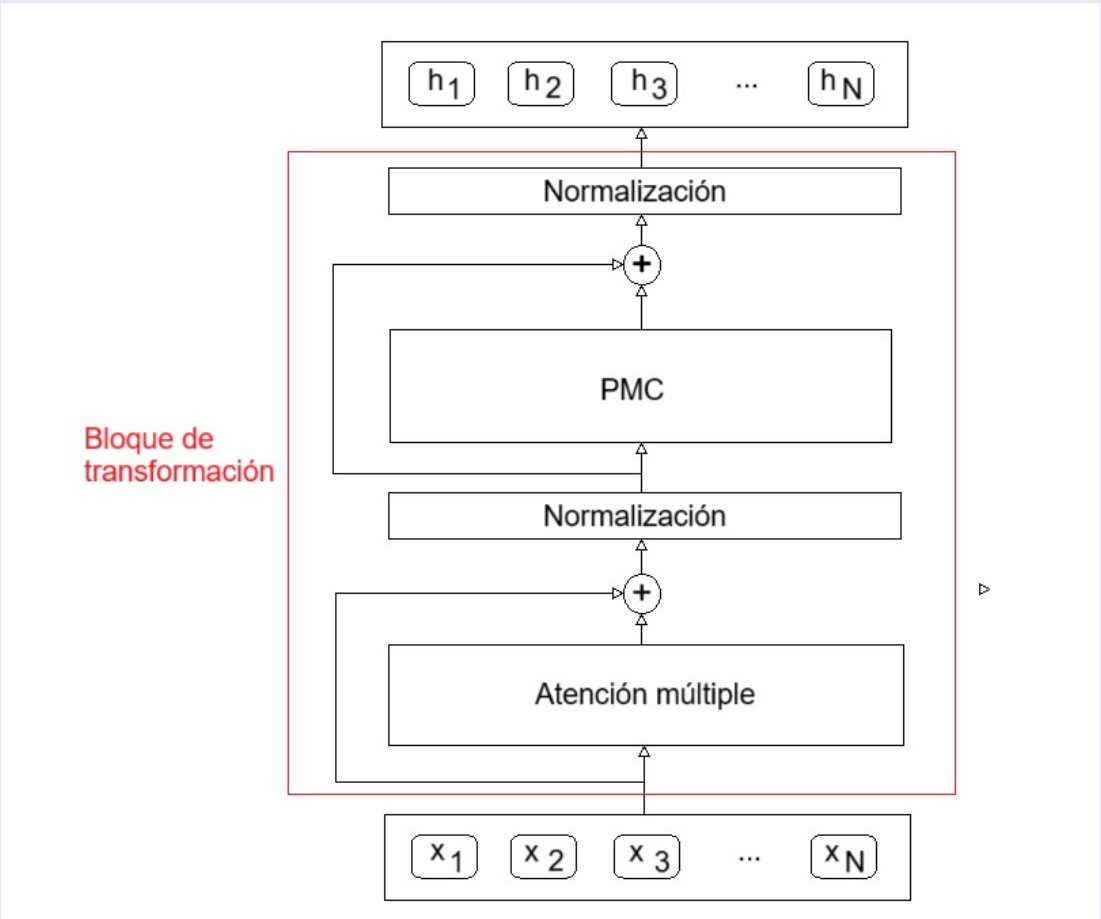
Bloque de transformación

- También podemos expresar las transformaciones dentro de cada bloque de transformación considerando variables intermedias $T \in R^{N \times d}$ como:

$$T^1 = autoAtencion(X)$$
$$T^2 = X + T^1$$
$$T^3 = Normalizacion(T^2)$$
$$T^4 = PMC(T^3)$$
$$T^5 = T^3 + T^4$$
$$H = Normalizacion(T^5).$$

Transformador

Bloque de transformación.



Transformador

Bloque de transformación

- El bloque de transformación tiene como entrada una matriz de $N \times d$ y como salida una matriz de $N \times d$.
- Esto permite apilar bloques.
- Chat-GPT3 para modelos de pequeños lenguajes tiene 12 bloques mientras que para grandes lenguajes tiene 96.

Transformador

Bloque de transformación.

- Fijarse que la representación de un dado token *i* cambia al final de la bloque de transformación.
- Esta nueva representación tiene en cuenta la representación original del token pero también su relación con los otros tokens de la entrada.